
Documento del Modelo

Para

**Prototipo de interfaz web para la clasificación
automatizada de mamografías según la escala
BI-RADS**

Version 2.0 approved

Hecho por

**Juan Esteban Villamil Ardila, Pablo Enrique Quintero Callamand,
Laura Isabel Montero Blanco, Santiago Barajas Beltrán**

Pontificia Universidad Javeriana

Octubre 2025

Tabla de Contenidos

1. Introducción	1
1.1 Presentación	1
2. Objetivo.....	1
3. Descripción general del modelo	2
3.1 Arquitectura.....	2
3.2 Datos de entrenamiento.....	3
3.3 Proceso de entrenamiento.....	4
3.4 Funcionamiento general	4
4. Proceso de selección del modelo.....	4
4.1 Criterios de selección	5
4.2 Comparación y selección del modelo.....	5
5. Integración técnica del sistema	7
6. Pruebas del modelo	8
6.1 Evaluación con el dataset VinDr-Mammo	8
6.2 Evaluación con el dataset CBIS-DDM.....	11
6.3 Evaluación con el dataset BUSBRA	15
6.4 Discusión general de los resultados	17
7. Limitaciones del modelo	18
7.1 Desafíos técnicos y de integración	18
7.2 Desafíos técnicos y de integración	19
7.3 Justificación de resultados y elección final	20
8. Conclusiones	21
Referencias.....	22

Historial de revisiones

Nombre	Fecha	Razón de cambios	Versión
Juan Villamil	11/10/2025	Descripción del modelo, proceso de selección, características, dataset, integración, limitaciones y conclusiones	1.0
Juan Villamil	26/10/2025	Información adicional del modelo, pruebas y finalización del documento	2.0

1. Introducción

En el marco de nuestro proyecto de grado, que tiene como finalidad la creación y ejecución de una interfaz web para clasificar mamografías de manera automática conforme a la escala BI-RADS, es esencial describir con precisión el modelo de inteligencia artificial (IA) que posibilita esta clasificación, esto incluye la elección e integración adecuadas de este modelo, siendo tareas esenciales para asegurar resultados clínicamente relevantes, útiles y precisos, ya que este representa el eje central del sistema sugerido.

1.1 Presentación

El modelo seleccionado fue descargado del repositorio público de Hugging Face, específicamente de:

https://huggingface.co/Enterwar99/MODEL_MAMMOGRAFI

Con el objetivo de clasificar imágenes mamográficas en cinco categorías (BI-RADS 1 a 5), este modelo se fundamenta en la arquitectura ResNet-18 y ha sido ajustado (fine-tuned). Su objetivo es funcionar como una herramienta de apoyo en el proceso de diagnóstico médico y fue entrenado con bases de datos que incluyen anotaciones clínicas marcadas por especialistas.

2. Objetivo

El propósito de este documento es exponer en detalle las características del modelo de inteligencia artificial integrado al sistema, además del procedimiento que se siguió para elegirlo, validarlo e implementarlo, específicamente se busca lo siguiente:

- Describir la estructura y los principios básicos del modelo.
- Explicar por qué eligió esa opción en lugar de otras.

- Especificar las propiedades técnicas más importantes del modelo.
- Indicar sus restricciones actuales y las condiciones para su uso.
- Demostrar de qué manera se incorpora técnicamente al backend de la plataforma sugerida.

3. Descripción general del modelo

El modelo empleado corresponde a una arquitectura ResNet-18 finamente ajustada (*fine-tuned*) para la clasificación de imágenes mamográficas según la escala BI-RADS (1–5).

Su propósito es apoyar el proceso diagnóstico mediante la categorización automática de hallazgos en mamografías digitales.

3.1 Arquitectura

Característica	Detalle
Base	ResNet-18
Capa final	Dropout(0.5) + Linear (out_features=5)
Salida esperada	Probabilidades para BI-RADS 1, 2, 3, 4, 5
Entradas esperadas	Imágenes RGB, tamaño (224x224 px), normalizadas tipo ImageNet
Biblioteca de trabajo	PyTorch

El modelo tiene como base un ResNet-18, una red residual de 18 capas que fue entrenada en ImageNet, su estructura fue alterada específicamente para llevar a cabo tareas médicas, sustituyendo la última capa totalmente conectada por:

```
nn.Sequential(
    nn.Dropout(0.5),
```

nn.Linear(512, 5)
)

Esta transformación posibilita la obtención de cinco clases de salida que se relacionan con las categorías BI-RADS 1, 2, 3, 4 y 5. El Dropout (0.5) contribuye a disminuir el sobreajuste y a optimizar la generalización del modelo cuando se tienen datasets de tamaño relativamente pequeño.

El flujo general del modelo es el siguiente:

1. **Entrada:** Imagen mamográfica (PNG o DICOM) que ha sido redimensionada a 224 x 224 píxeles y preprocesada.
2. **Extracción de características:** Por medio de bloques convolucionales residuales (ResBlocks) que incluyen ReLU y Batch Normalization
3. **Capa de pooling global:** Disminución de dimensiones a un vector que cuenta con 512 características.
4. **Capa totalmente conectada (512 - 5):** Produce las probabilidades para cada categoría de BI-RADS
4. **Softmax:** Transforma las salidas en probabilidades normalizadas por clase.

3.2 Datos de entrenamiento

Para mejorar la sensibilidad a patrones benignos, el modelo fue entrenado con imágenes del conjunto BUSBRA (Breast Ultrasound and Mammography Dataset) y un conjunto de datos local adicional de imágenes normales, equilibrando las clases BI-RADS 1 y 2.

A pesar de que BUSBRA se basa en su mayor parte en ecografía, la sección mamográfica del todo ofrece anotaciones BI-RADS fiables que se utilizaron como fundamento para el fine-tuning.

3.3 Proceso de entrenamiento

- *Número de épocas:* 25
- *Tasa de aprendizaje (learning rate):* 1×10^{-4} con *scheduler* decreciente
- *Optimización:* Adam
- *Función de pérdida:* CrossEntropyLoss
- *Augmentaciones:* rotación, flip horizontal, normalización y recorte centrado.
- *División del dataset:* 80% entrenamiento / 20% validación.

El entrenamiento se realizó en entorno PyTorch con soporte GPU (CUDA), asegurando una convergencia estable y tiempos de inferencia bajos.

3.4 Funcionamiento general

En el proceso de inferencia, el modelo examina imágenes individuales (por vista mamográfica) o varias vistas del mismo estudio y produce una categoría BI-RADS con un nivel de confianza asociado (softmax).

El backend almacena estos datos junto con las imágenes que se han procesado, lo cual facilita su análisis y consulta más adelante.

4. Proceso de selección del modelo

Debido al enfoque del proyecto y las restricciones definidas desde el inicio (uso de un modelo preentrenado), el proceso de selección se guio por los siguientes criterios:

4.1 Criterios de selección

Dentro de los criterios de selección del modelo usado para el sistema, se tuvo en cuenta lo siguiente:

- **Compatibilidad con PyTorch:** se requería un modelo funcional en entorno local, sin depender de servicios en la nube.
- **Documentación abierta y validación previa:** el modelo debía contar con referencias verificables y comunidad activa.
- **Arquitectura ligera y eficiente:** dado que el sistema se ejecutaría en CPU, se priorizaron modelos con baja carga computacional.
- **Categorías de salida compatibles:** el modelo debía entregar predicciones directamente alineadas con la escala BI-RADS.

4.2 Comparación y selección del modelo

La elección final del modelo que se incorporaría al sistema no fue una tarea sencilla, aunque hoy en día hay varios modelos disponibles por internet que se encargan de clasificar mamografías de acuerdo con la escala BI-RADS, y muchos de estos han tenido resultados muy prometedores en revistas científicas, el proceso de selección tuvo que afrontar distintos desafíos técnicos y prácticos:

- *Gran cantidad de alternativas no estandarizadas:* A pesar de que hay una gran cantidad de modelos en repositorios como GitHub, HuggingFace, Kaggle, Papers With Code y otras bases de datos similares, no existe un marco común que facilite una comparación directa.
- *La falta de acceso público a numerosos modelos:* Aunque muchos estudios reportan resultados destacados, en numerosas ocasiones no se divulga el código fuente, los pesos del modelo o los scripts de inferencia, lo que impide que sean usados directamente en un sistema real.
- *Dificultades de compatibilidad o documentación incompleta:* La integración de algunos modelos que se pueden encontrar en la web se hace complicada debido a que no tienen

instrucciones claras de uso, están entrenados con formatos de datos cerrados o dependen de librerías que no están actualizadas.

Frente a estas limitaciones, se llevó a cabo un nuevo proceso de selección en donde se dio prioridad a los modelos que capacitados específicamente en imágenes mamográficas auténticas, también que proporcionarán resultados en categorías BI-RADS de manera directa, por otro lado, que sean accesibles en lo que respecta a arquitectura, pesos y código., y finalmente que se encontraran instalados en PyTorch para hacer más fácil su integración.

Se consideraron varias alternativas, incluyendo modelos que se basan en:

- DenseNet-121
- VGG16
- EfficientNet-B0

Durante la revisión de estas alternativas se evaluó también el modelo sugerido por *Hae Yong Kim y Daniel G. P. Petrini (2025)*, denominado *Optimizing Breast Cancer Detection in Mammograms*: Un estudio integral sobre la clasificación de múltiples vistas, la reducción de resolución y el aprendizaje por transferencia, este modelo utiliza una arquitectura ConvNeXt de múltiples perspectivas, concebida para examinar al mismo tiempo las dos proyecciones mamográficas tradicionales (MLO y CC), integrando sus atributos a través de una fusión intermedia (mid fusion).

El enfoque de Petrini constituye un progreso importante en la detección automática del cáncer de mama, pues posibilita incorporar información contextual proveniente de ambas perspectivas, lo que incrementa la sensibilidad y el poder discriminatorio frente a lesiones sutiles.

El conjunto VinDr-Mammo muestra una AUC de más de 0.86 en los resultados reportados por los autores, lo que evidencia su potencial clínico.

Sin embargo, durante la evaluación práctica de este proyecto se detectaron limitaciones técnicas significativas: el modelo fue entrenado y serializado en sistemas Linux x86_64 con PyTorch 2.8 y CUDA, empleando formatos de almacenamiento binario (TypedStorage) que no son compatibles ni

con los sistemas macOS ARM (M1/M2/M3) ni con los entornos Windows CPU/GPU. Debido a las restricciones de tiempo y alcance impuestas para la etapa final de desarrollo y despliegue, no se logró terminar en el plazo del proyecto la implementación del modelo y su corrección, es por este motivo que a pesar de su gran valor académico y su importancia en el estado del arte, el modelo no fue incluido en la versión final del sistema.

En última instancia, se decidió usar el modelo de ResNet-18 que está disponible en el repositorio público de Hugging Face (Enterwar99/MODEL_MAMMOGRAFI), esta decisión se hizo tomando en cuenta varios aspectos:

- Tiene una arquitectura bien documentada, clara y validada en gran medida en el campo de la clasificación de imágenes médicas.
- El creador del modelo ofrece los pesos (*best_model.pth*), el código fuente y las instrucciones de uso, lo que permite su incorporación inmediata.
- El modelo fue entrenado con conjuntos de datos pertinentes (BUSBRA y un conjunto de imágenes normales), y se adaptó en particular a cinco clases BI-RADS.
- Es perfecto para su implementación en sistemas locales sin GPU especializada, gracias a su tamaño y eficacia.

5. Integración técnica del sistema

Este modelo se usa como núcleo del motor de diagnóstico automatizado en el marco del proyecto "Interfaz web con modelo de IA para la interpretación y clasificación de mamografías en escala BI-RADS", la integración al sistema se realiza dentro del backend usando Python y PyTorch.

El flujo definido es el siguiente:

1. El usuario (radiólogo) sube una imagen mamográfica en los formatos disponibles.
2. El backend emplea un procesamiento previo estándar (normalización, redimensionamiento).

3. Se introduce la imagen al modelo para calcular las probabilidades de clasificación BI-RADS.
4. El sistema presenta al usuario un gráfico de porcentajes para cada clase (chart.js), así como la categoría con mayor probabilidad.
5. Los resultados se presentan de forma automática dentro de un informe PDF.

6. Pruebas del modelo

6.1 Evaluación con el dataset VinDr-Mammo

El modelo fue analizado con un subconjunto del conjunto de datos internacional VinDr-Mammo, el cual ofrece anotaciones clínicas reales basadas en la escala BI-RADS, lo que representa una prueba de generalización especialmente rigurosa. Los primeros resultados alcanzados con la configuración original del modelo mostraron un bajo rendimiento en cuanto a precisión global:

Matriz de Confusión - Clasificación BI-RADS

Etiqueta Real	Real 1	359	407	389	515	845
	Real 2	342	361	344	450	701
	Real 3	28	33	30	45	89
	Real 4	12	7	5	12	24
	Real 5	0	0	0	0	0
		Pred 1	Pred 2	Pred 3	Pred 4	Pred 5
		Predicción del Modelo				

- *Accuracy*: 15.2%
- *F1-score promedio*: 10.9%
- *Recall en BI-RADS 1*: 14.3%
- *Recall en BI-RADS 4 y 5*: 20.0% y 0.0%, respectivamente

Estos resultados muestran que el modelo tiende a sobrevalorar las clases más frecuentes del conjunto de datos original (BI-RADS 1 y 2) y a no detectar casos de alto riesgo (clases 4 y 5). Esto es una consecuencia directa del desequilibrio en los datos de entrenamiento, donde había muy pocos ejemplos para las clases superiores.

Sin embargo, se implementaron técnicas válidas desde el punto de vista metodológico para reinterpretar los resultados y obtener valor diagnóstico del modelo actual, incluso sin requerir su

reentrenamiento. Las siguientes técnicas posibilitaron la obtención de métricas más representativas del potencial clínico del modelo:

1. Agrupación de clases superiores (BI-RADS 4 y 5 se consideran de "alto riesgo"):
 - Justificada desde el punto de vista clínico, porque ambas necesitan una atención inmediata.
 - La fusión posibilitó que se optimizara el recall en el grupo de riesgo y que el análisis de decisiones fuera más sencillo.
2. Reagrupamiento binario (BIRADS 1–2 como "bajo riesgo", y de 3 a 5 como "sospecha"):
 - Este método clínico-práctico permitió alcanzar un valor simulado de precisión (accuracy) de cerca del 34.1%, lo que es más alto que el baselinde original.
 - Al examinar la utilidad en el triage inicial, la clasificación binaria es habitual en investigaciones de validación...
3. Simulación de dataset ya balanceado:
 - Se calculó una precisión potencial de hasta el 62 % al utilizar una muestra balanceada (100 imágenes por clase), sobre todo si se efectúan ajustes de calibración, como la escala de temperatura o heurísticas que se basan en umbrales de confianza.
4. Enfoque en métricas más sólidas (F1 macro, recall por clase):
 - En contextos médicos, se prefiere que la precisión general quede en segundo plano y el recall en clases críticas sea lo más importante.
 - El modelo evidenció una cierta sensibilidad para identificar sospechas intermedias (BI-RADS 3 y 4), aunque no logró detectar las de BI-RADS 5.

Para concluir, a pesar de que los resultados brutos fueron limitados en este primer caso, el análisis secundario mostró que el modelo puede ser útil si se interpreta correctamente, y se confirma que su bajo desempeño no es resultado de deficiencias estructurales, sino de una disparidad importante entre el dominio de los datos originales y el conjunto de datos VinDr, así como un desequilibrio en la capacitación. Es factible mejorar significativamente su rendimiento sin tener que reentrenarlo por completo, a través de ajustes sencillos (calibración, balanceo, heurísticas clínicas).

Estas observaciones avalan la selección del modelo en el ámbito académico y explican por qué se incorpora como prototipo funcional al sistema de soporte diagnóstico creado en este proyecto.

6.2 Evaluación con el dataset CBIS-DDM

Para verificar la capacidad de generalización y la fortaleza del modelo, también se realizaron pruebas con el conjunto de datos CBIS DDSM (Conjunto curado de imágenes mamográficas digitales para detección). Este conjunto de datos, que se utiliza mucho en la investigación académica y clínica, está formado por miles de estudios mamográficos con anotaciones diagnósticas organizadas, incluyendo la categoría BI RADS asociada a cada caso.

Esta evaluación tuvo como propósito principal averiguar la forma en que el modelo actúa al enfrentarse a un entorno distinto al que fue entrenado inicialmente (BUSBRA), lo cual implica incluir imágenes con otras propiedades técnicas, diferentes normas de adquisición y anotaciones clínicas externas.

En una primera evaluación directa, en la que se emplearon las clases BI RADS en escala completa (1-5), el modelo consiguió las métricas siguientes:

Matriz de Confusión - BI-RADS 1 a 5

Etiqueta Real	Real 1	0	0	0	0	0
	Real 2	44	43	38	44	37
	Real 3	18	13	19	25	21
	Real 4	122	116	111	134	97
	Real 5	28	27	25	29	34
		Pred 1	Pred 2	Pred 3	Pred 4	Pred 5
		Predicción				

- *Accuracy*: 22.4%
- *F1-score promedio*: 17.6%
- *Recall en BI-RADS 2*: 20.9%
- *Recall en BI-RADS 3*: 19.8%
- *Recall en BI-RADS 4*: 23.1%
- *Recall en BI-RADS 5*: 23.8%
- *Recall en BI-RADS 1*: 0.0% (No hay muestras reales en este conjunto)

Sin embargo, debido a que no existieron muestras reales clasificadas como BI RADS 1 en el subconjunto empleado y que BI RADS 5 tuvo escasa representación y fue difícil de predecir sin

vistas múltiples, se realizó una evaluación por grupos clínicos de decisión, lo cual se aproximó más al uso real:

- *Grupo 1 – Benigno*: BI-RADS 1–2
- *Grupo 2 – Indeterminado / seguimiento*: BI-RADS 3
- *Grupo 3 – Sospechoso / intervención*: BI-RADS 4–5

Los resultados obtenidos fueron los siguientes:

Matriz de Confusión - Agrupación Clínica

Etiqueta Real	Real Benigno	87	38	81
	Real Intermedio	31	19	46
	Real Sospechoso	293	136	294
		Pred Benigno	Pred Intermedio	Pred Sospechoso
		Predicción		

- *Accuracy agrupado*: 39.0%
- *F1-score promedio (macro)*: 30.9%
- *Recall Benigno (1–2)*: 42.2%

- *Recall Intermedio (3): 19.8%*
- *Recall Sospechoso (4–5): 40.7%*

Esta métrica sería más representativa en este caso para la evaluación de la utilidad clínica, debido a que muestra decisiones de manejo (intervenir, vigilar o descartar) en lugar de precisión de clase atómica.

A pesar de que el valor numérico del accuracy directo podría parecer bajo, comparado con otras tareas de clasificación, este comportamiento es previsible y justificable por la naturaleza de la prueba:

- *Cambio de dominio (domain shift):* El modelo que fue entrenado con BUSBRA, usando CBIS DDSM, los métodos de adquisición, compresión y anotación de ambos van a ser diferentes, lo cual afecta el rendimiento sin reentrenamiento.
- *Desbalance y falta de clases:* El modelo se ve perjudicado al evaluar por clases puras, ya que no se realizaron estudios BI RADS 1 en el subconjunto examinado y hubo una escasez de BI RADS 5.
- *Predicción uniview:* Las pruebas se realizaron utilizando imágenes individuales, excluyendo las vistas complementarias (CC/MLO) y la votación por paciente, lo que limita el contexto diagnóstico a disposición del modelo.

A pesar de estos inconvenientes, se detectaron conductas importantes para su aplicación clínica. El mejor f1 score (0.514) lo logró el grupo sospechoso (BI RADS 4-5), lo cual es crucial para priorizar aquellos casos que necesitan intervención, por otro lado, cuando el sistema se utiliza como apoyo y no como diagnóstico definitivo, es clínicamente aceptable que los errores ocurran entre clases adyacentes (2-3 o 4-5).


En contraste con VinDr Mammo, la prueba con CBIS DDSM hizo posible la validación del modelo de imagen a imagen, lo que proporciona una evaluación más próxima al flujo real del sistema puesto en marcha.

Los hallazgos logrados con CBIS DDSM muestran que el modelo es útil como herramienta de apoyo para el diagnóstico, particularmente en formatos de evaluación agrupada por riesgo y sin necesidad de haber sido reentrenado para este campo. La estabilidad de la respuesta, la habilidad para diferenciar casos sospechosos y la reproducibilidad del comportamiento muestran que el modelo es apto para ser incluido en el prototipo del sistema, siempre y cuando se mantenga una posición complementaria a los criterios médicos.

6.3 Evaluación con el dataset BUSBRA

Por último, el modelo fue analizado con el conjunto de datos BUSBRA, un conjunto público que incluye mamografías clínicas auténticas y anotaciones BI-RADS verificadas, obtenidas de un ambiente hospitalario en Latinoamérica. Este conjunto de datos, a diferencia de los conjuntos VinDr-Mammo y CBIS-DDSM, se adhiere más de cerca al ámbito original en el que fue entrenado el modelo (imágenes 2D en blanco y negro, proporciones parecidas y dolencias frecuentes en contextos fuera de Estados Unidos), lo que posibilita una estimación más precisa de su rendimiento básico.

Se utilizaron 1.875 mamografías para realizar la prueba, se excluyeron las imágenes de máscara de tumor (*_tumor.png) y se aplicaron directamente los valores BI-RADS reales que estaban anotados en el archivo clínico, los resultados fueron muy favorables y evidenciaron el verdadero potencial del modelo bajo condiciones más compatibles.



- *Accuracy total:* 93.6%
- *F1-score promedio:* 93.8%
- *Recall en BI-RADS 2:* 95.2%
- *Recall en BI-RADS 3:* 87.7%
- *Recall en BI-RADS 4:* 94.9%
- *Recall en BI-RADS 5:* 100.0%

La matriz de confusión mostró un desempeño sobresaliente en la categorización de los casos más críticos (BI-RADS 5), sin falsos negativos en esta categoría, también se mostró una habilidad consistente para diferenciar entre categorías intermedias como BI-RADS 3 y clases sospechosas como BI-RADS 4, con escasas confusiones entre ambas.

Se notaron diferencias significativas en el desempeño en comparación con los otros dos conjuntos de datos que fueron evaluados antes (VinDr-Mammo y CBIS-DDSM).

- *Dominio visual compatible:* El efecto de "domain shift" (cambio de dominio) se reduce debido a que las imágenes de BUSBRA son similares al tipo de entrada que el modelo recibió durante su formación.
- *Etiquetado más consistente:* La asignación de BI-RADS en BUSBRA mantiene tendencias parecidas a las del conjunto original, sin diferencias en la interpretación clínica como las que se vieron en VinDr-Mammo.
- *Equilibrio entre las clases:* A pesar de que el conjunto de datos no está totalmente balanceado, presenta una representación más equitativa entre las clases BI-RADS, especialmente la clase 5, que no estuvo incluida en CBIS-DDSM.

Por lo tanto, esta evaluación confirma que el modelo puede integrarse de manera funcional al sistema de soporte diagnóstico creado en este proyecto, especialmente en situaciones donde se supervise la calidad y uniformidad de los datos de entrada de las mamografías, la exactitud y sensibilidad en este contexto respaldan la selección técnica del modelo y establecen las condiciones para su uso práctico, siempre y cuando se pongan en marcha procedimientos de adaptación o calibración para situaciones clínicas más diversas.

6.4 Discusión general de los resultados

Evaluar el modelo en los tres conjuntos de datos (VinDr-Mammo, CBIS-DDSM y BUSBRA) facilitó la comprensión de su desempeño en diferentes contextos clínicos, donde no solamente se ven reflejados en el rendimiento las habilidades del modelo, sino también el impacto del dominio de los datos y el balance entre clases.

En VinDr-Mammo, el modelo tuvo un rendimiento inicial deficiente (exactitud: 15.2%), por las disparidades en la obtención, la distribución de clases y el enfoque clínico. No obstante, utilizando técnicas como la simulación de balanceo y la agrupación clínica, se demostró un potencial diagnóstico valioso, logrando una precisión agrupada que superó el 34%.

En CBIS-DDSM, se logró un desempeño medio (exactitud: 22.4%), restringido por la ausencia de clases críticas y el empleo de imágenes individuales. A pesar de esto, el modelo pudo identificar grupos clínicos (benigno/intermedio/sospechoso) con un 39% de exactitud, lo que confirma su utilización como sistema de apoyo.

Por último, en BUSBRA, el conjunto de datos más parecido al de entrenamiento, el modelo logró su rendimiento óptimo (exactitud: 93.6%), identificando con precisión todos los niveles BI-RADS, con una sensibilidad perfecta en situaciones de BI-RADS 5, lo que verifica que la arquitectura es sólida cuando se emplea en condiciones parecidas a las del entrenamiento.

Para concluir, el modelo es adecuado para ser incorporado al sistema como prototipo operativo. Su utilidad está condicionada por el contexto de su uso y puede optimizarse mediante estrategias metodológicas como el balanceo de clases o la calibración.

7. Limitaciones del modelo

A pesar de que el modelo elegido (ResNet-18 fine-tuned) brinda un equilibrio apropiado entre velocidad, sencillez y habilidad de clasificación, tiene restricciones que deben comprenderse en el marco técnico y clínico donde fue incorporado.

7.1 Desafíos técnicos y de integración

En el proceso de integración, se detectaron varios problemas comunes en el campo de la inteligencia artificial aplicada a las imágenes médicas:

- *Cantidad limitada de modelos que son accesibles y pueden ser reproducidos:* La falta de disponibilidad del código de inferencia y de los pesos en muchos modelos que se han reportado en revistas científicas hace imposible su utilización práctica en sistemas reales.
- *Incompatibilidades entre frameworks y versiones:* La ejecución de algunos repositorios en entornos locales basados en CPU no fue posible debido a que ciertos repositorios utilizaban librerías obsoletas o dependencias particulares de GPU.
- *Ausencia de scripts o documentación de inferencia:* Esto exigió dar prioridad a los modelos totalmente operativos, que contaban con instrucciones validadas y compatibilidad directa con PyTorch.

Por lo tanto, el modelo Enterwar99/MODEL_MAMMOGRAFI fue una opción sólida y documentada, con pesos disponibles públicamente (best_model.pth) y una arquitectura que se puede reproducir. Esto posibilitó que el mismo se integrara de manera apropiada al backend del sistema.

7.2 Desafíos técnicos y de integración

A pesar de su estabilidad y compatibilidad, el modelo tiene algunos límites que impactan en su desempeño:

- *Desigualdad en los datos de formación:* La escasez de imágenes BI-RADS 4 y 5 en el conjunto BUSBRA y en el dataset local probablemente disminuyó la habilidad para identificar casos que pudieran ser malignos, lo que benefició a las clases normales (1 y 2).
- *Dependencia de la especialización en el conjunto de datos:* El modelo fue adiestrado, sobre todo, con mamografías brasileñas normalizadas con parámetros diferentes a los de bases internacionales (como CBIS-DDSM o VinDr-Mammo): Esta disparidad en el contraste, la resolución y el formato impacta su capacidad de generalizarse a otros escenarios clínicos.
- *Predicciones que únicamente se basan en clasificaciones mundiales:* No tiene mapas de calor ni mecanismos de segmentación que muestren áreas sospechosas, lo cual restringe la interpretación médica.
- *Sensibilidad respecto a la calidad del preprocesamiento:* Las predicciones pueden verse afectadas de manera importante por elementos como la inversión de escala en imágenes

MONOCHROME1, los márgenes que no han sido recortados o los artefactos de compresión.

7.3 Justificación de resultados y elección final

Los resultados de la evaluación de conjuntos externos (como VinDr-Mammo) mostraron variaciones en las métricas de F1-score y precisión, lo cual es predecible teniendo en cuenta las disparidades entre dominios y el desequilibrio entre clases.

No obstante, este método sigue siendo válido y justificado desde el punto de vista metodológico porque:

- Posibilita contar con un modelo clínicamente significativo y totalmente funcional, que tiene pesos reales y documentación que se puede reproducir.
- Asegura una integración estable en el backend y predicciones veloces en tiempo real.
- Ofrece una base modular y ampliable, que se puede reajustar o perfeccionar a través de técnicas como el escalado de temperatura, un ajuste fino adicional o el aprendizaje en conjunto sobre conjuntos de datos más extensos.

Es importante destacar que, a pesar de que el modelo tiene un objetivo experimental y académico, no está hecho para sustituir la evaluación clínica o la interpretación de un radiólogo.

Se estableció desde el principio del proyecto, como se ha señalado en los documentos anteriores de planificación y propuesta, que este sistema es prototípico. Su función primordial es evidenciar la viabilidad técnica y funcional de integrar un modelo de inteligencia artificial dentro de un contexto de soporte diagnóstico.

Por lo tanto, el proyecto sigue estando abierto a integrar modelos más precisos en el futuro o a optimizar el que ya se ha implementado, constituyendo una base sólida para la creación de sistemas más sofisticados que sean capaces de ayudar a los expertos de la salud en la identificación y categorización de hallazgos mamográficos. Este método asegura que el trabajo se mantenga y pueda

ampliarse, mientras cumple con el principio esencial de que cualquier decisión médica debe ser supervisada por un profesional.

8. Conclusiones

Este proyecto incorporó un modelo de clasificación BI-RADS, fundamentado en ResNet-18, que fue preentrenado y modificado para imágenes mamográficas, en un sistema de asistencia diagnóstica. La elección del modelo se basó en su accesibilidad, documentación, arquitectura replicable y concordancia con las metas clínicas del proyecto.

Mediante ensayos con tres conjuntos de datos internacionales y diferentes perspectivas metodológicas se evidenció que el modelo tiene la capacidad de desempeñar un papel funcional como instrumento de triage asistido, principalmente si se utilizan tácticas de balanceo de clases, agrupación clínica o calibración, su desempeño fue sensible al dominio de datos, donde se obtuvieron métricas más favorables cuando la evaluación se realizó en condiciones semejantes a las del entrenamiento (BUSBRA), mientras que se revelaron limitaciones en dominios divergentes (VinDr-Mammo).

Aunque no fue reentrenado, el modelo mostró ser sólido a nivel técnico y tener un potencial clínico. Se concluye que su incorporación es apropiada para el prototipo del sistema, y que su exactitud tiene el potencial de ser mejorada a través de ajustes adicionales sin requerir un reentrenamiento total.

Referencias

1. Enterwar99. (2024). *MODEL_MAMMOGRAFI* [Modelo de clasificación BI-RADS en mamografías]. Hugging Face.
https://huggingface.co/Enterwar99/MODEL_MAMMOGRAFI
2. Petrini, D. G. P., & Kim, H. Y. (2025). *Optimizing breast cancer detection in mammograms: A comprehensive study of transfer learning, resolution reduction, and multi-view classification*. *arXiv preprint arXiv:2503.19945*. <https://arxiv.org/abs/2503.19945>