

Prototipo de interfaz web para la clasificación automatizada de mamografías según la escala BI-RADS



**INFORME DEL PROYECTO FINAL DE PREGRADO REALIZADO PARA CUMPLIR UNO DE
LOS REQUISITOS DEL TÍTULO DE INGENIERO DE SISTEMAS**

Autores:

Juan Esteban Villamil Ardila

Pablo Enrique Quintero Callamand

Laura Isabel Montero Blanco

Santiago Barajas Beltrán

Directora

Ing. Andrea Del Pilar Rueda Olarte Ph.D.

**PONTIFICIA UNIVERSIDAD JAVERIANA
FACULTAD DE INGENIERIA
PROGRAMA PREGRADO INGENIERIA DE SISTEMAS
BOGOTÁ, D.C.
NOVIEMBRE, 2025**

Rector de la Pontificia Universidad Javeriana

Luis Fernando Múnera Congote, S.J.

Decano Facultad de Ingeniería

Ing. Diego Alejandro Patiño Guevara, Ph.D.

Director del Departamento de Ingeniería de Sistemas

Ing. Andrea Del Pilar Rueda Olarte Ph.D.

Artículo 23 de la Resolución No. 1 de junio de 1946

“La Universidad no se hace responsable de los conceptos emitidos por sus alumnos en sus proyectos de grado. Sólo velará porque no se publique nada contrario al dogma y la moral católica y porque no contengan ataques o polémicas puramente personales. Antes bien, que se vean en ellos el anhelo de buscar la verdad y la Justicia”

AGRADECIMIENTOS

Queremos expresar nuestro más profundo agradecimiento a nuestra directora de proyecto de grado y actual directora de carrera, Andrea del Pilar Rueda Olarte, por su orientación y apoyo durante el desarrollo de este proyecto. Su experiencia, dedicación y acompañamiento fueron esenciales para lograr los objetivos planteados

Juan Esteban Villamil Ardila

Quiero agradecer de corazón a mi familia por su constante acompañamiento y motivación durante el desarrollo de este trabajo de grado; todas mis metas y objetivos son por y para ustedes.

También quiero expresar mi profunda gratitud a mi pareja por su comprensión y apoyo incondicional, que han sido esenciales en esta última etapa de mi carrera. Sin todos ustedes, no habría meta que fuera capaz de alcanzar.

Pablo Enrique Quintero Callamand

A toda mi familia, en especial a mi madre, por apoyarme a lo largo de mi carrera y ayudarme a reconocer mi potencial. A mis compañeros de trabajo, por su constante colaboración y dedicación por realizar este proyecto.

Laura Isabel Montero Blanco

Quiero agradecer a Dios por darme la oportunidad de tener educación y darme la fortaleza en esta etapa. También a mi familia y a mis compañeros por su dedicación en este proyecto, y un agradecimiento muy especial a mi madre por ser tan incondicional en mi vida y a lo largo de mi carrera, así como a mi padre por su hidalguía, e incluyendo a mi hermana Geraldine y a mi mascota Isaías por su compañía.

Santiago Barajas Beltrán

Quiero expresar mi profundo agradecimiento a mi familia, cuyo apoyo incondicional, paciencia y confianza fueron fundamentales para culminar este proyecto de grado. Agradezco también a mis compañeros de trabajo, por su dedicación, compromiso y colaboración constante durante cada etapa del desarrollo.

CONTENIDO

RESUMEN	IX
ABSTRACT	X
INTRODUCCIÓN	1
DESCRIPCION GENERAL	2
1. OPORTUNIDAD, PROBLEMA	2
1.1. Contexto del problema	3
1.2. Formulación del problema	4
1.3. Propuesta de solución	6
1.4. Justificación del problema	7
2. DESCRIPCIÓN DEL PROBLEMA	8
2.1. Objetivo General	10
2.2. Objetivos Específicos	10
2.3. Resultados, normas y justificación	10
I- CONTEXTO DEL PROBLEMA	11
1. TRASFONDO	12
2. ANÁLISIS DEL CONTEXTO	13
II- ANALISIS DEL PROBLEMA	16
1. REQUERIMIENTOS	16
2. RESTRICCIONES	18
3. ESPECIFICACIÓN FUNCIONAL	19
3.1 Funcionalidad: Carga de estudios mamográficos	19
3.2 Funcionalidad: Visualización e interacción con imágenes	19
3.3 Funcionalidad: Clasificación automática de BI-RADS	20
3.4 Funcionalidad: Visualización de resultados de análisis	20
3.5 Funcionalidad: Generación de reportes de análisis	21
3.6 Funcionalidad: Gestión de usuarios y autenticación	21
3.7 Resumen de requerimientos funcionales	21
III- DISEÑO DE LA SOLUCIÓN	22
4. ARQUITECTURA GENERAL DEL SISTEMA	22
Diagrama BPMN	23
Arquitectura de alto nivel	23
Diagrama de despliegue	24

5.	DISEÑO FUNCIONAL.....	25
5.1	<i>Estructura funcional general</i>	25
5.2	<i>Diseño Funcional</i>	25
5.3	<i>Módulos de soporte</i>	26
6.	DISEÑO DE LA INTERFAZ DE USUARIO	26
7.	DISEÑO LÓGICO Y DE COMPONENTES	31
8.	SELECCIÓN Y JUSTIFICACIÓN DE HERRAMIENTAS	32
9.	TECNOLOGÍAS DE APOYO	33
10.	CONSIDERACIONES DE CALIDAD Y SEGURIDAD	34
11.	RESUMEN DEL DISEÑO	34
IV- DESARROLLO DE SOLUCIÓN		34
1.	METODOLOGÍA DE DESARROLLO.....	35
1.1.	<i>Estructura general de trabajo</i>	35
1.2.	<i>Cronología de trabajo por sprints</i>	36
1.3.	<i>Resultados de la metodología</i>	37
2.	DESCRIPCIÓN DEL SISTEMA EN FUNCIONAMIENTO	38
3.	COMPONENTES ADICIONALES	46
11.1	<i>Backend y control de servicios (FastAPI)</i>	46
11.2	<i>Base de datos (PostgreSQL)</i>	47
11.3	<i>Módulo de almacenamiento temporal de archivos</i>	47
11.4	<i>Módulo de generación de reportes (ReportLab)</i>	48
11.5	<i>Módulo de auditoría y registro</i>	48
4.	DESPLIEGUE Y VALIDACIÓN	49
4.1	<i>Arquitectura de despliegue</i>	49
4.2	<i>Despliegue en Google Cloud</i>	49
5.	MODELO DE INTELIGENCIA ARTIFICIAL INTEGRADO.....	50
5.1.	<i>Arquitectura y parámetros</i>	50
5.2.	<i>Datos esperados por el modelo</i>	51
5.3.	<i>Integración dentro del backend</i>	51
6.	CONCLUSIONES DEL DESARROLLO	53
V- RESULTADOS		53
	<i>Unitarias</i>	53
	<i>Seguridad</i>	54

<i>Carga</i>	54
<i>Usabilidad</i>	54
VI- CONCLUSIONES	55
1. ANÁLISIS DE IMPACTO DEL PROYECTO	55
<i>Impacto a corto y medio plazo</i>	55
<i>Impacto a largo plazo</i>	55
<i>Impacto en ingeniería de sistemas</i>	55
<i>Impacto global</i>	55
2. CONCLUSIONES Y TRABAJO FUTURO	55
VII- REFERENCIAS	56
VIII- APENDICE	57

LISTA DE FIGURAS

Figura 1: Modelo MVC.....	23
Figura 2: Diagrama BPMN.....	24
Figura 3: Arquitectura de alto nivel.....	25
Figura 4: Diagrama de despliegue.....	25
Figura 5: Diagrama de flujo.....	27
Figura 6: Mockup Pantalla Principal.....	28
Figura 7: Mockup Interfaz de Carga de Estudios.....	28
Figura 8: Mockup Pantalla de análisis.....	29
Figura 9: Mockup Resultados y gráficas.....	30
Figura 10: Mockup Visor de imágenes médicas.....	31
Figura 11: Mockup Reporte en PDF.....	31
Figura 12: Diagrama de clases.....	33
Figura 13: Pantalla de inicio de sesión (login/).....	39
Figura 14: Pantalla de registro de usuario (register/).....	40
Figura 15: Pantalla de carga de imágenes (upload/).....	40
Figura 16: Pantalla de análisis (proceso de inferencia).....	41
Figura 17: Pantalla de resultados (report/).....	42
Figura 18: Visor de imágenes médicas (visor-cornerstone/).....	44
Figura 19: Reporte descargable en PDF.....	45
Figura 20: Componente de información (info/).....	46
Figura 21: Componente de perfil (perfil/).....	46
Figura 22: Componente de reportes (reportes/).....	47

LISTA DE TABLAS

Tabla 1: Entregables, normas y justificación del proyecto.....	11
Tabla 2: Soluciones similares existentes.....	15
Tabla 3: Selección y justificación de herramientas.....	34
Tabla 4: Cronograma de Sprints.....	37
Tabla 5: Tablas de la base de datos.....	48
Tabla 6: Despliegue de cada componente.....	50

RESUMEN

Este proyecto presenta el desarrollo de una interfaz web clínica diseñada para apoyar el diagnóstico e interpretación de mamografías por medio de inteligencia artificial. El sistema integra una red neural convolucional ResNet-18 preentrenada para realizar la clasificación automática BI-RADS (1-5), asistiendo radiólogos a identificar potenciales anomalías de seno. Permite la carga segura de imágenes (DICOM/JPG/PNG/TIF), análisis en base a probabilidades, y reportes PDF automáticos con controles de acceso en base a roles. Los resultados demuestran la viabilidad técnica, usabilidad, confiabilidad y potencial del sistema para mejorar la detección temprana de cáncer de seno por medio de evaluaciones estandarizadas y eficientes asistidas por IA.

ABSTRACT

This project presents the development of a clinical web interface designed to support the diagnostic interpretation of mammograms through artificial intelligence. The system integrates a pre-trained ResNet-18 convolutional neural network to perform automatic BI-RADS classification (1–5), assisting radiologists in identifying potential breast abnormalities. It enables secure image upload (DICOM/JPG/PNG/TIF), probability-based analysis, and automatic PDF reporting with role-based access control. The results demonstrate the system’s technical reliability, usability, and potential to enhance early breast cancer detection through standardized and efficient AI-assisted evaluation.

INTRODUCCIÓN

El presente documento hace parte de la memoria del trabajo de grado titulado “Prototipo de interfaz web para la clasificación automatizada de mamografías según la escala BI-RADS”, que fue elaborado como parte del programa de Ingeniería de Sistemas en la Pontificia Universidad Javeriana. Este trabajo es la síntesis de todo el procedimiento de investigación, diseño, desarrollo, validación y documentación correspondiente a un sistema informático clínico enfocado en respaldar el diagnóstico en mamografía a través de la inteligencia artificial (IA).

El cáncer de mama, que es una de las causas más relevantes de mortalidad en mujeres a nivel global, motivó a la creación de este proyecto como respuesta a un problema que tiene un impacto significativo en la salud pública, pues a pesar de que las mamografías son el instrumento más eficaz para detectar la enfermedad en sus primeras etapas, su interpretación depende principalmente del criterio y la experiencia del radiólogo, lo cual puede provocar variaciones en los diagnósticos y retrasos en los procedimientos clínicos. En estas circunstancias, la implementación de modelos de inteligencia artificial para clasificar imágenes médicas se muestra como una opción factible para mejorar la exactitud, disminuir las equivocaciones humanas y potenciar el proceso laboral en el ámbito clínico.

El propósito principal de este proyecto fue crear y poner en funcionamiento una interfaz web que integrara un modelo de aprendizaje profundo ya entrenado para categorizar mamografías digitales según la escala BI-RADS (Breast Imaging Reporting and Data System). El sistema brinda al usuario las probabilidades vinculadas a cada una de las categorías, así como la opción de producir automáticamente un informe clínico en PDF. Con el fin de que la privacidad de los datos médicos se respete según los estándares internacionales de seguridad de la información (ISO/IEC 27001), se creó esta herramienta para funcionar en contextos hospitalarios locales.

Este documento describe todo el proceso del proyecto, desde la detección del problema y el análisis de los requisitos hasta el diseño técnico, la implementación de los componentes, la integración del modelo de IA y la validación del sistema mediante pruebas con software y con usuarios finales. Además, se muestran las proyecciones futuras del sistema, los efectos logrados y los resultados conseguidos.

DESCRIPCION GENERAL

1. Oportunidad, problema

El cáncer de mama ha venido siendo una de las principales causas de mortalidad en mujeres a nivel mundial, además de un desafío de gran prioridad para los sistemas de salud globales. La detección temprana realizada mediante la mamografía representa una de las herramientas más efectivas para mejorar la tasa de supervivencia y reducir considerablemente los tratamientos invasivos; sin embargo, este proceso de interpretación de imágenes mamográficas depende en gran medida del criterio del radiólogo, que en ocasiones puede variar dependiendo de la experiencia o la carga laboral del mismo, entre otros factores que generan una variabilidad diagnóstica y aumentan el riesgo de error humano.

En Colombia, como en otros países de América Latina, los centros de diagnóstico suelen tener problemas y limitaciones en cuanto a infraestructura tecnológica y disponibilidad de expertos, lo que puede provocar demoras en el tiempo de lectura, además de un exceso de trabajo para estandarizar los informes clínicos. La clasificación de los hallazgos de una mamografía se lleva a cabo siguiendo las pautas del American College of Radiology (ACR) y haciendo uso de la escala BI-RADS (Breast Imaging Reporting and Data System). Este sistema logra la clasificación de lesiones mamarias en función de su grado de sospecha de malignidad. Sin embargo, el mismo se ha considerado muy subjetivo ya que requiere tanto de una interpretación detallada como de un entrenamiento especializado para asegurar la consistencia entre los observadores.

Simultáneamente, en la última década se ha evidenciado un incremento exponencial en los progresos de la inteligencia artificial (IA), particularmente hablando en el área del aprendizaje profundo, gracias a la aplicación de redes neuronales convolucionales (CNN) para el análisis de imágenes médicas, estas tecnologías han mostrado un rendimiento similar e incluso más alto que el de radiólogos con experiencia en ciertas tareas de detección y clasificación, lo que, aunque no buscan ser una especie de “reemplazo”, las establece como una herramienta prometedora para la asistencia diagnóstica. No obstante, la mayoría de las soluciones existentes están restringidas únicamente al campo académico, lo que genera obstáculos técnicos para su implementación en entornos clínicos locales debido al tratamiento de datos sensibles de salud.

Ante este escenario, se pudo detectar una oportunidad evidente, crear un sistema de software clínico que incorpore un modelo de inteligencia artificial ya entrenado para clasificar mamografías automáticamente y que tenga la capacidad de funcionar en una infraestructura controlada accesible desde instituciones médicas, que logre proteger los datos médicos y también proporcionar resultados que sean reproducibles, transparentes y fáciles de entender para los expertos en salud. Esta oportunidad no solo satisfacía una necesidad médica, sino que también marca un propósito social y educativo que se alinea con la misión de la Pontificia Universidad Javeriana al fomentar un uso ético y responsable de la tecnología en favor de la salud.

Por lo tanto, este proyecto se centró en el diseño y la implementación de una interfaz web médica desplegada en la nube que incorpora un modelo de inteligencia artificial validado con anterioridad. Esto posibilita que el personal clínico pueda subir estudios mamográficos digitales, recibir una categorización automática según la escala BI-RADS y producir informes estructurados. De modo que ayuda a disminuir la carga operativa, además que también ayuda a estandarizar el proceso de diagnóstico y a mejorar la calidad de atención para las pacientes.

1.1. Contexto del problema

Este proyecto se desarrolló en el ámbito de la ingeniería de sistemas aplicada a la salud, un área que ha cobrado mucha relevancia en los últimos años debido a su potencial para combinar tecnologías de información, ciencia de datos e inteligencia artificial en la práctica clínica. El evidente progreso en la potencia de cómputo y el desarrollo de las redes neuronales convolucionales (CNN) han hecho posible idear soluciones informáticas que tienen la capacidad de procesar imágenes médicas con un nivel de exactitud similar al del ojo experimentado, lo que ha creado nuevas posibilidades para optimizar la calidad y la eficacia en los diagnósticos.

En el campo particular de la radiología mamaria, se ha establecido el uso de la inteligencia artificial como una opción efectiva para ayudar al radiólogo en trabajos que requieren mucha carga visual o son repetitivos, como lo son la detección de microcalcificaciones, masas o distorsiones arquitectónicas. Sin embargo, el uso de estas herramientas en situaciones reales se ha visto obstaculizado por elementos como la falta de estandarización de interfaces o algunas limitaciones jurídicas relacionadas con el tratamiento de datos clínicos, por lo que se halla reto principal la necesidad de contar con sistemas locales que puedan ser auditados y que sean compatibles con las políticas de privacidad institucionales.

En este marco, la Pontificia Universidad Javeriana promovió el desarrollo de proyectos de grado que unieran las exigencias reales de la sociedad con los fundamentos técnicos y éticos de la ingeniería. El presente trabajo cumplió con ese propósito al desarrollar una solución tecnológica que, a través de la creación de una interfaz web local con un modelo de inteligencia artificial integrado, ayudara a reforzar el diagnóstico precoz del cáncer mamario y a emplear de manera responsable las tecnologías emergentes en medicina.

El desarrollo se basó en una perspectiva modular basada en la estructura cliente-servidor. Para la interfaz de usuario, se utilizó Angular, mientras que se usó FastAPI para la integración del modelo de inteligencia artificial y la lógica comercial. Este modelo, entrenado con datos internacionales de mamografías hasta octubre del 2023, permitió la clasificación automática de acuerdo a la escala BI-RADS, proporcionando resultados en términos de probabilidad por categoría y permitiendo la posibilidad de producir informes clínicos en PDF.

El proyecto, además de su componente técnico, se desarrolló en el contexto de los desafíos regulatorios y éticos que implica la utilización de inteligencia artificial en el campo de la medicina. Por lo tanto, se desarrolló la solución para que funcione dentro de una infraestructura controlada y privada dentro de la nube, asegurando así el acatamiento de la Ley 1581 del 2012 sobre protección de datos personales y la conformidad con las normas ISO/IEC 27001 en materia de seguridad informativa.

Así, el proyecto se desarrolló en un contexto interdisciplinario que reunió la ética, la ingeniería y la medicina, mostrando que el desarrollo de software clínico no debía concentrarse únicamente en la eficacia y el rendimiento, sino también en la seguridad, la fiabilidad y la trazabilidad de los procedimientos. El prototipo generado, además de alcanzar las metas técnicas, aspira a ofrecer una solución relevante al problema de la fluctuación en los diagnósticos y el tiempo que tarda en responderse cuando se leen mamografías.

1.2. Formulación del problema

Se observó que, pese al avance significativo de los modelos de inteligencia artificial en la detección del cáncer de mama, no había herramientas confiables, locales y accesibles que incorporaran estas tecnologías en un flujo de trabajo clínico real. En instituciones

de escasos recursos o con políticas de confidencialidad médica muy estrictas, las soluciones que existían a nivel global no eran viables porque se presentaban muchas restricciones técnicas o se hallaban bajo licencias comerciales.

Por otro lado, los sistemas hospitalarios convencionales no disponían de instrumentos que utilizaran el aprendizaje profundo para clasificar las mamografías de manera automática y uniformizar los informes clínicos de acuerdo con la escala BI-RADS, lo que posiblemente conllevaba a que los radiólogos tuvieran que examinar a mano cada estudio, incrementando los tiempos de espera, la carga laboral y con ello la probabilidad de que los diagnósticos variaran.

Por lo tanto, el problema se planteó de la siguiente manera:

“¿Cómo llevar a cabo el diseño y la implementación de un sistema web que integre un modelo de inteligencia artificial previamente entrenado para clasificar mamografías digitales basándose en la escala BI-RADS, que funcione en una infraestructura controlada, accesible remotamente desde contextos clínicos, protegiendo la privacidad de los datos y respaldando la interpretación médica con confiabilidad y estandarización?”

Enfrentar este problema supuso solucionar diversos desafíos técnicos y metodológicos. Primero, era necesario garantizar que el modelo de IA se integrara de manera eficaz con una interfaz web moderna, que tuviera la capacidad de manejar imágenes médicas en dos de los formatos de imágenes médicas más usados en radiología (DICOM, TIF) sin poner en riesgo la calidad del diagnóstico ni los plazos de procesamiento. En segundo lugar, el sistema necesitaba funcionar de forma independiente en una infraestructura controlada, sin depender de servicios públicos de terceros, lo que obligó a que se diseñara una arquitectura modular y contenedorizada. Por último, se tenían que asegurar el cumplimiento de los estándares de privacidad, trazabilidad y seguridad, condiciones que son necesarias para su posible implementación en hospitales reales.

Por lo tanto, el planteamiento del problema orientó todo el proceso de desarrollo hacia la generación de un prototipo funcional que integrara la exactitud del modelo de inteligencia artificial con una interfaz clínica segura e intuitiva, lo que ayudó a fortalecer la práctica radiológica y a utilizar mejor las tecnologías emergentes en la medicina.

1.3. Propuesta de solución

Para hacer frente a la problemática detectada, el proyecto propuso desarrollar un prototipo de interfaz web médica que incorporara un modelo de inteligencia artificial ya entrenado, capaz de categorizar mamografías digitales en función de la escala BI-RADS (1 a 5). Este sistema fue creado con una perspectiva modular y segura, enfocándose en la implementación local en contextos clínicos, garantizando que las regulaciones de protección de datos personales se cumplan.

El desarrollo del sistema se organizó en tres elementos fundamentales:

- *Frontend (Angular)*: Se encarga de proporcionar una interfaz actualizada, intuitiva y enfocada en el usuario médico que permita cargar imágenes de mamografías con formatos DICOM, JPG, PNG o TIF, ver los resultados de clasificación y crear informes en PDF. Su diseño se enfocó en ser claro, minimalista, en permitir navegar fácilmente y con pocos clics y en adaptarse a varios dispositivos clínicos.
- *Backend (FastAPI)*: Se desarrolló como una API REST para manejar la interacción entre el modelo de inteligencia artificial, la base de datos y la interfaz de usuario, este componente es responsable de procesar las imágenes, invocar el modelo de clasificación y devolver los resultados de forma organizada y segura. Además, incorpora funciones para controlar el acceso y autenticar a los usuarios de acuerdo con su rol (técnico, radiólogo o administrador).
- *Módulo de Inteligencia Artificial*: Se basa en un modelo ResNet-18 que se encuentra en el repositorio de Hugging Face. La razón por la que se eligió dicho modelo fue su adaptabilidad y facilidad para su integración dentro de nuestro sistema, así como su aptitud para ambientes clínicos experimentales. El modelo entrenado junto a sus pesos (*best_model.pth*) se incorporó al sistema para hacer inferencias directamente en el servidor de nube asignado con una precisión aceptable y tiempos de respuesta clínicamente viables (*Documento del Modelo*).

Además, se creó un módulo que produce reportes automáticamente en formato PDF y permite agregar en el las imágenes cargadas, los porcentajes de probabilidad por categoría BI-RADS y las observaciones del usuario radiólogo. Cada estudio procesado se

vincula con un identificador único, lo que hace más fácil documentar los resultados y la documentación clínica.

El despliegue del sistema se realizó en una máquina virtual de Google Cloud, que corre un contenedor Docker y engloba todos los servicios del sistema: el backend en FastAPI, la base de datos PostgreSQL y el frontend en Angular. De esta forma el sistema se lleva a cabo de manera remota dentro de la infraestructura de Google Cloud. Esto posibilita que se pueda acceder al contenedor y gestionar su ejecución centralmente y con seguridad. Esta táctica aseguró que el prototipo fuera portable, mantenible y escalable, lo que permite mejorar en el futuro, por ejemplo al integrar nuevos modelos o volver a entrenar el modelo actual o a incluir nuevas herramientas para el análisis visual como las segmentación de lesiones o los mapas de calor.

En conclusión, esta propuesta representa una solución viable, práctica y alineada con los estándares de software y clínicos, y proporciona al radiólogo una herramienta de ayuda que mezcla seguridad en la gestión de información sensible, facilidad de uso y precisión técnica.

1.4. Justificación del problema

La alternativa propuesta abordó a una necesidad única en el campo de la medicina y la tecnología, optimizar la eficacia y precisión al interpretar mamografías a través de instrumentos seguros, accesibles y adaptados a las circunstancias locales de los centros de salud. Debido a que la carga de trabajo de los radiólogos es alta y la variabilidad en el diagnóstico puede conllevar un peligro clínico, desarrollar sistemas de soporte fundamentados en inteligencia artificial se volvió una prioridad para mejorar los procedimientos de detección temprana del cáncer mamario.

Desde un punto de vista clínico, el sistema propuesto brinda un soporte adicional al especialista, posibilitando una clasificación automática por medio de la escala BI-RADS con porcentajes de probabilidad por categoría, lo que ayuda a tomar decisiones médicas fundamentadas y a disminuir los plazos para realizar análisis. Esta automatización no buscó ni buscará reemplazar el juicio profesional, sino que refuerza la precisión del diagnóstico al obtener una segunda opinión técnica reproducible, ayudando a cumplir las directrices internacionales de diagnóstico radiológico que el American College of Radiology (ACR) ha establecido.

El proyecto evidenció que se pueden integrar modelos de inteligencia artificial preentrenados en contextos clínicos reales siempre y cuando se sigan procedimientos seguros y controlados, esto se logró mediante una estructura que utiliza Angular, FastAPI y

contenedores Docker que funcionan en una máquina virtual de Google Cloud, lo que permitió la implementación de manera efectiva, modular y desde distintos entornos. Emplear esta infraestructura garantizó que toda la información sensible permaneciera bajo control del sistema y se ajustara a las regulaciones sobre protección de datos, logrando así un equilibrio entre la seguridad y el rendimiento.

La implementación del modelo ResNet-18 demostró que las soluciones abiertas y reproducibles tienen el potencial de llegar a niveles apropiados de rendimiento para el soporte diagnóstico, siempre que se implemente un diseño de software que se ajuste a los distintos estándares. Así, el proyecto integró varias de las buenas prácticas de ingeniería con la ética médica y la protección de datos personales, asegurando confidencialidad e integridad a lo largo de todo el flujo.

Por último, desde un punto de vista académico y social, la elaboración de este prototipo significó una contribución concreta para fortalecer la salud pública y educar ingenieros que estén comprometidos con el bien colectivo. El trabajo realizado hizo posible mostrar que la tecnología, al crearse de manera responsable, puede conectar a la ingeniería con la medicina al incrementar el acceso a herramientas para diagnósticos y promover la innovación local en entornos clínicos.

En conclusión, son tres aspectos esenciales los que sustentan la justificación de este proyecto, la viabilidad tecnológica, la responsabilidad social y la pertinencia médica. Todos estos guiaron cada una de las decisiones tomadas durante el diseño, desarrollo e implementación del sistema, lo que reforzó la importancia de la propuesta en el ámbito de la ingeniería biomédica aplicada.

2. Descripción del problema

El objetivo del proyecto fue diseñar, implementar y validar un prototipo funcional de una interfaz web médica, destinada a clasificar mamografías automáticamente de acuerdo con la escala BI-RADS, para ayudar al personal clínico en la interpretación de exámenes digitales de las mamas. Este sistema integral de soporte diagnóstico fue desarrollado como una solución que fusiona métodos avanzados de inteligencia artificial con normas de seguridad clínica y principios del diseño de software enfocado en el usuario.

Para lograr esta meta, se desarrolló una interfaz web desplegada en nube privada controlada que consta de tres componentes fundamentales:

- Una interfaz gráfica de usuario desarrollada en Angular, la cual posibilita cargar estudios en diversos formatos de Figura médica (DICOM, JPG, PNG, TIF), observar los resultados de clasificación y también bajar informes clínicos en formato PDF.
- Una API de backend, desarrollada en FastAPI, que se encarga de organizar el intercambio entre el modelo de inteligencia artificial, la interfaz y la base de datos PostgreSQL, esta también es la responsable del control de acceso y autenticación.
- Un módulo para clasificar automáticamente, basado en un modelo ResNet-18 que ha sido entrenado previamente para identificar y clasificar mamografías de acuerdo a la escala BI-RADS (1 a 5), este modelo fue incorporado de manera nativa en el sistema para poder hacer inferencias locales, lo que asegura que la velocidad sea rápida y la privacidad de los datos esté garantizada.

Este prototipo proporciona una experiencia de uso creada concretamente para los profesionales de la salud, entregando un entorno visual simple y flexible. Después de cargar las imágenes mamográficas, el sistema utiliza el modelo de inteligencia artificial para procesar los datos y presentar al usuario las probabilidades relacionadas con cada categoría BI-RADS, así como las imágenes procesadas previamente. Además, permite elaborar un informe clínico automático con los resultados.

La aplicación se implementó en la infraestructura a través de una máquina virtual en Google Cloud que ejecuta un contenedor Docker, esto posibilitó que el funcionamiento y el mantenimiento del sistema se centralizara sin la necesidad de equipos locales, asegurando una alta disponibilidad y un acceso remoto seguro al flujo informativo. De igual manera, el empleo de contenedores estandarizados garantizó la portabilidad y uniformidad del entorno de ejecución al cumplir con los principios de confidencialidad y trazabilidad que son necesarios para aplicaciones clínicas.

Mediante este desarrollo, se intentó ofrecer una herramienta útil que disminuyera la carga operativa de los radiólogos y el tiempo de análisis, y a la vez que estandarizara el procedimiento de clasificación y elaboración de informes. El resultado final fue un prototipo funcional, validado y documentado que muestra las ventajas técnicas de incorporar modelos de inteligencia artificial en contextos clínicos reales, bajo condiciones controladas y siguiendo los estándares de privacidad y rendimiento.

2.1. Objetivo General

El objetivo general del proyecto fue desarrollar e implementar una interfaz web que integrara un modelo de inteligencia artificial para la interpretación de mamografías con enfoque en la clasificación BI-RADS, la solución debe facilitar la clasificación según la escala BI-RADS, además de optimizar el apoyo diagnóstico a radiólogos y garantizar precisión y usabilidad en entornos clínicos.

2.2. Objetivos Específicos

1. Desarrollar una interfaz web que permita cargar mamografías y procesarlas con un modelo de IA para su clasificación según la escala BI-RADS.
2. Implementar la visualización de la clasificación BI-RADS en un formato claro y accesible para los radiólogos.
3. Evaluar la precisión del modelo mediante pruebas comparativas con diagnósticos médicos reales.
4. Optimizar la experiencia de usuario asegurando que la interfaz sea intuitiva y fácil de integrar en el flujo de trabajo clínico.

2.3. Resultados, normas y justificación

Resultados	Normas Estándar	Justificación
SRS – Software Requirements Specefication	IEEE 830 ISO IEC 25010	Establece los requisitos no funcionales y los funcionales y las limitaciones del sistema. Asegura una descripción formal y comprobable de las funciones del prototipo y los requerimientos del usuario clínico.
SDD – Software Design Document	IEEE 1016 ISO IEC 19505 (UML 2.5)	Presenta la arquitectura del sistema, los diagramas de componentes, los casos de uso y el despliegue. Define las decisiones en términos de diseño técnico, las tecnologías empleadas (PostgreSQL, Docker, GC, FastAPI y Angular) y el sistema modular.
Documento del Modelo	IEEE 1471 FAIR Principles ISO/IEC 22989	Describe cómo se integra el modelo de IA (ResNet-18) dentro del sistema, además de los procedimientos de inferencia, la normalización de imágenes y las métricas obtenidas en

		cuanto a rendimiento. Garantiza que el componente de inteligencia artificial sea transparente y reproducible.
Documento de Pruebas	IEEE 829 ISO IEC IEEE 29119	Incluye la planeación, implementación y resultados de las pruebas unitarias, de integración y funcionales aplicadas al sistema. Analiza la exactitud del modelo, lo establece que es el software y la experiencia de los usuarios en el contexto simulado de una clínica.
Manual de Usuario	ISO IEC 26514	Incluye instrucciones para la carga de imágenes, la visualización de resultados, la interpretación de probabilidades y la creación de reportes, además brinda indicaciones completas para que los radiólogos puedan utilizar el sistema. Hace más fácil la implementación del sistema en situaciones reales.
Plan de Proyecto (PMP)	IEEE 1058 PMBOK (PMI)	Especifica la planificación en términos de tiempo, los recursos humanos y técnicos, los riesgos, el método ágil utilizado (Scrum) y el seguimiento de las entregas. Asegura una gestión eficaz del ciclo de vida del proyecto.
Propuesta para Proyecto de Grado (VFP)	Lineamientos de la Pontificia Universidad Javeriana	Define la justificación, el alcance y la visión inicial del proyecto. Es el documento fundamental para la autorización por parte de la dirección del programa de continuar desde la planeación del proyecto de grado
Prototipo funcional	ISO IEC 25010 ISO IEC 27001 GNU GPLv3	Entregable principal del proyecto. Garantiza la usabilidad, la seguridad y la capacidad de reproducir en entorno privado controlado, simbolizando la integración total entre el interfaz web y el modelo de IA. Satisface los estándares de calidad y confidencialidad requeridos en un software médico.

Tabla 1: Entregables, normas y justificación del proyecto

I- CONTEXTO DEL PROBLEMA

1. Trasfondo

El cáncer de mama es una de las enfermedades con mayor efecto en la salud pública global, ya que es el tipo de cáncer más común en las mujeres y una de las causas principales de muerte (OPS/OMS, 2025). Se ha evidenciado que el diagnóstico temprano es la táctica más eficaz para mejorar la tasa de supervivencia y disminuir la necesidad de terapias invasivas. En este marco, la mamografía se ha establecido como el método principal de diagnóstico para la detección temprana dado que posibilita reconocer lesiones sospechosas en el tejido mamario antes de que sean perceptibles desde un punto de vista clínico.

Sin embargo, la interpretación mamográfica está sujeta en gran parte a la experiencia, la carga de trabajo o al juicio personal del radiólogo, lo que puede provocar variaciones en la exactitud diagnóstica y tener un impacto negativo en el tiempo adecuado para el tratamiento, esta dependencia de la evaluación humana revela la importancia de contar con instrumentos que unifiquen el proceso diagnóstico y respalden las decisiones clínicas, en particular en contextos donde hay limitaciones de infraestructura médica o personal.

El American College of Radiology (ACR) creó el sistema BI-RADS (Breast Imaging Reporting and Data System), definido como una escala categórica que organiza los resultados mamográficos desde los que necesitan estudios adicionales hasta los que tienen una fuerte sospecha de malignidad, con la finalidad de unificar criterios interpretativos, este sistema se ha adoptado de forma internacional, lo que ha posibilitado la homogeneización de los informes radiológicos junto a la disminución de la ambigüedad en el análisis clínico (American College of Radiology, 2013).

Al mismo tiempo, el avanzado progreso de la inteligencia artificial (IA) ha cambiado el análisis de imágenes médicas, pues las redes neuronales convolucionales (CNN), en específico, se han establecido como un instrumento muy efectivo para clasificar imágenes de manera automática, segmentar estructuras anatómicas y reconocer patrones complejos. Estas arquitecturas posibilitan el procesamiento veloz y consistente de volúmenes amplios de datos, proporcionando resultados reproducibles y que disminuyen el impacto del error humano (LeCun, Bengio & Hinton, 2015).

La incorporación de un estándar clínico como el sistema BI-RADS dentro de modelos de inteligencia artificial ofrece una oportunidad para crear sistemas que ayuden en el diagnóstico y que sean capaces de mejorar el flujo de trabajo médico, disminuir la carga

operativa de los radiólogos y aumentar la exactitud en la detección temprana del cáncer mamario. Esta perspectiva está alineada con la tendencia mundial de la medicina asistida por inteligencia artificial, que fomenta soluciones tecnológicas que acompañan el trabajo del especialista sin sustituirlo.

En este contexto, este proyecto se situó en el cruce entre la ingeniería de sistemas y la práctica médica, desarrollando un prototipo de interfaz web para clasificar mamografías automáticamente según la escala BI-RADS. Esta solución, que fue diseñada bajo los principios de reproducibilidad y seguridad en mente, combina los progresos de las redes neuronales convolucionales con la estandarización clínica. Su objetivo es optimizar el diagnóstico y respaldar el trabajo del personal de radiología, proporcionando una herramienta que se puede implementar en situaciones reales.

2. Análisis del contexto

En el contexto global, se han creado varias soluciones que utilizan inteligencia artificial para respaldar el diagnóstico temprano del cáncer de mama con el propósito de ayudar a los radiólogos a interpretar mamografías y acortar la duración de los análisis, a pesar de que estos avances han mostrado un gran potencial para clasificar las lesiones mamarias y estandarizar los informes clínicos, todavía se encuentran con obstáculos técnicos y económicos en su adopción masiva.

Los sistemas basados en la base de datos Digital Database for Screening Mammography (DDSM) son uno de los primeros referentes en esta área, esta ha sido ampliamente usada para proyectos de investigación y para el entrenamiento de modelos de aprendizaje profundo, donde se ha llegado a un rendimiento similar al de radiólogos experimentados en tareas de clasificación y detección de lesiones (Lee et al., 2017) gracias a la capacitación de las redes neuronales con este conjunto de datos. Su principal fortaleza es que existen datos públicos, estandarizados y curados dentro de ella, lo que ha posibilitado la validación de arquitecturas y la replicación de experimentos en contextos académicos, sin embargo, su principal limitación es que la mayoría de los modelos derivados de DDSM no han sido validados en situaciones clínicas reales, lo que disminuye su capacidad para integrarse en flujos hospitalarios de este mismo tipo.

Las grandes empresas de tecnología también han promovido soluciones con un gran impacto científico y mediático en una escala más avanzada, un sistema de apoyo diagnóstico basado en aprendizaje profundo desarrollado por Google Health, logró disminuir considerablemente los falsos positivos y negativos al interpretar mamografías,

incluso sobrepasando la exactitud media de los radiólogos individuales (McKinney et al., 2020), siendo su mayor fortaleza la capacidad de acceder a grandes volúmenes de datos, a una infraestructura computacional potente y a protocolos de evaluación multicéntricos. No obstante, su naturaleza propietaria establece restricciones significativas para su utilización en entidades de salud con recursos limitados o con normativas estrictas de privacidad médica.

De igual manera, la compañía Kheiron Medical Technologies ha creado instrumentos comerciales para identificar anomalías en mamografías, entre los que se halla el sistema Mia que actualmente se encuentra siendo validado clínicamente en Europa. Estas soluciones se distinguen por su perspectiva clínica realista y su propósito enfocado en la integración hospitalaria, lo que representa un progreso relevante en la aplicación práctica de la inteligencia artificial al diagnóstico mediante mamografías (Kheiron Medical Technologies, 2023), debido a su naturaleza cerrada y sus elevados costos de licencia, este tipo de sistemas cuentan con limitaciones que dificultan su accesibilidad en entidades locales o con tecnología más limitada.

En contraste, la solución que se ha desarrollado para este proyecto propone un enfoque abierto y reproducible, centrado en la incorporación de un modelo de inteligencia artificial preentrenado (ResNet-18) en una interfaz web médica modular, este sistema fue creado para ser desplegado de manera controlada en infraestructura dedicada (Google Cloud), lo que fortalece la supervisión sobre la privacidad y el cumplimiento normativo sin tener que recurrir a servicios comerciales externos. De igual manera, la integración directa en el flujo de trabajo del radiólogo se facilita gracias a la arquitectura de software, que se basa en FastAPI, Angular y PostgreSQL, que se hace posible por medio de las siguientes funciones: carga de imágenes con formatos estándar (PNG, JPG, DICOM, TIF), clasificación automática con un informe de probabilidades para cada categoría BI-RADS, visualización ordenada de resultados y elaboración automática de informes en PDF.

El sistema tiene otra ventaja competitiva que parte de su eficacia en términos de recursos, la moderación de los requerimientos computacionales hace posible que pueda ejecutarse en instituciones con infraestructura escasa, lo que contribuye a que se adopte en entornos de salud locales. Cuando se combinan factores como la seguridad de los datos y la facilidad de integración, estos suman un valor extra en comparación con las

soluciones propietarias, por lo que este prototipo se manifiesta como una opción robusta y escalable para ajustarse a las exigencias del sistema sanitario latinoamericano y colombiano.

Solución	Tipo de desarrollo	Ventajas principales	Limitaciones identificadas	Enfoque de implementación
DDSM (Digital Database for Screening Mammography)	Base de datos académica usada para investigación y entrenamiento de modelos	Permite reproducibilidad de experimentos clínicos y entrenamiento de CNN en datos curados, es de uso libre para investigación	No validado en entornos clínicos; los modelos derivados no siempre generalizan bien	Entorno académico y de investigación
Google Health AI System	Sistema propietario de apoyo diagnóstico basado en deep learning	Alta precisión, reducción de falsos positivos y negativos, uso de grandes volúmenes de datos multicéntricos	No accesible públicamente, restricciones éticas y de privacidad	Implementación en centros hospitalarios de alto nivel
Kheiron Medical Technologies Mia	Software comercial validado clínicamente en Europa	Integración hospitalaria, diseñado para acompañar al radiólogo en la lectura mamográfica y probado en clínicas reales	Alto costo de licencias, sistema cerrado, dependencia de proveedor externo	Implementación clínica certificada (CE/FDA en curso).
Prototipo RADS	BI- Interfaz web local con IA integrada (ResNet-18)	Clasificación automática BI-RADS, visor de imágenes, interfaz amigable, ejecución controlada en nube, generación	No alcanza la misma precisión diagnóstica que sistemas comerciales	Despliegue controlado en Docker / Google Cloud local

		de reportes PDF; a gran es- adaptable a infra-cala, en fase estructura limitada de valida- ción preclí- nica	
--	--	--	--

Tabla 2: soluciones similares existentes

La tabla muestra que las soluciones internacionales en inteligencia artificial aplicadas a la mamografía han mostrado progresos importantes en automatización y precisión diagnóstica, sin embargo, estas también tienen restricciones estructurales que dificultan su implementación en contextos locales. Los modelos académicos como los que provienen de la base DDSM, no están validados clínicamente, los sistemas a nivel corporativo como Google Health, no están disponibles públicamente por lo que su acceso es limitado, y las herramientas comerciales, como la de Kheiron conllevan costos elevados por licencia y entornos de implementación cerrados.

En contraste, el prototipo desarrollado se creó con un enfoque ético y accesible, cuyo objetivo es mejorar la capacidad de diagnóstico en entidades sanitarias que no dispongan de tecnología avanzada. La protección de datos y la integración directa en el flujo clínico son posibles gracias a su arquitectura modular basada en FastAPI, Angular y Docker Compose, por lo que el proyecto otorga un valor distintivo en comparación con las soluciones a nivel internacional, al dar prioridad a la privacidad, la adaptabilidad y el efecto sobre la sociedad en el terreno de salud pública.

II- ANALISIS DEL PROBLEMA

1. Requerimientos

Requisitos Funcionales

- RF-1. *Carga de imágenes*. El sistema debe admitir la carga de estudios mamográficos en los formatos. dicom/.dcm, jpeg/.jpg, png/.tif y .tiff, si el modelo de inteligencia artificial no procesa DICOM de manera nativa, la plataforma cambiará las imágenes a formato PNG automáticamente, informando al usuario sobre el posible efecto en la calidad y dando la opción de continuar o cancelar el procedimiento.
- RF-2. *Clasificación BI-RADS automática*. Después de que las imágenes se hayan cargado, el backend llamará al modelo ResNet-18, que ha sido previamente

elegido e incorporado, para calcular las probabilidades por categoría BI-RADS (del 1 al 5) y devolver los resultados a la interfaz del usuario.

- RF-3. *Visualización del resultado*. La interfaz mostrará las imágenes subidas, la probabilidad porcentual por cada categoría BI-RADS y un campo para comentarios clínicos. Asimismo, presentará los resultados clasificados por proyección (R-MLO, L-CC, R-CC y L-MLO) y destacará de manera automática la categoría más alta del estudio.
- RF-4. *Reporte descargable*. El sistema producirá un informe en PDF que contendrá el identificador del reporte, miniaturas de las imágenes, los resultados de la clasificación y las observaciones médicas, el usuario tendrá la opción de guardar el archivo en su computadora en la carpeta que elija.
- RF-5. *Tratamiento temporal de datos*. Durante el proceso de elaboración del informe, se administrarán temporalmente los datos del reporte, en esta versión del sistema no se conservará información clínica de forma permanente ni historial a largo plazo.
- RF-6. *Autenticación y control de acceso*. El acceso estará restringido mediante autenticación con rol para el radiólogo y tokens para proteger sesiones y recursos.

Requisitos no Funcionales

- RNF-1. *Procesamiento controlado y privacidad*. El procesamiento de información se llevará a cabo en una infraestructura específica (Google Cloud), bajo el control absoluto del equipo desarrollador y sin estar expuesto a servicios externos, lo que asegura la protección de los datos médicos.
- RNF-2. *Usabilidad y accesibilidad*. La interfaz debe ser fácil de usar, predecible y flexible para usuarios con diferentes grados de experiencia en tecnología. El sistema podrá ejecutarse en navegadores actualizados (Edge, Chrome, Firefox).
- RNF-3. *Rendimiento*. El sistema debe responder en períodos de tiempo clínicamente aceptables en hardware medio-alto. El desempeño se verá afectado por los recursos que haya disponibles (como la RAM, la CPU y la GPU) y mejorará si se emplean equipos con más capacidad.
- RNF-4. *Escalabilidad y mantenibilidad*. La arquitectura modular permitirá reemplazar el modelo de IA, agregar nuevas fuentes de Figura o modificar componentes sin afectar el resto del sistema.
- RNF-5. *Seguridad*. Se pondrán en marcha controles de seguridad para el almacenamiento y las comunicaciones, cifrado de credenciales, tokens que expiren

y se renueven automáticamente, así como políticas de acceso alineadas con buenas prácticas (ISO/IEC 27001).

Requisitos de datos e interoperabilidad

- RD-1. *Metadatos clínicos mínimos*. Se pondrán en marcha controles de seguridad para el almacenamiento y las comunicaciones, cifrado de credenciales, tokens que expiren y se renueven automáticamente, así como políticas de acceso alineadas con buenas prácticas (ISO/IEC 27001).
- RD-2. *Estándares de Figura*. Deben ser compatibles con JPG/PNG para mostrar y aceptar DICOM y TIF, al producirse una conversión, se registran las posibles restricciones o riesgos clínicos.
- RD-3. *Portabilidad de resultados*. Los informes en formato PDF tienen que ser legibles, trazables y compatibles con el archivo institucional para asegurar la integridad de los datos y la posibilidad de auditoría.

Requisitos regulatorios y de cumplimiento

- RC-1. *Protección de datos personales*. El sistema tiene que respetar la Ley 1581 del año 2012 y las normas sobre el tratamiento ético de datos delicados de salud en Colombia.
- RC-2. *Seguridad de la información*. Los controles de seguridad deben ajustarse a las normas ISO/IEC 27001:2022, que abarcan los principios de confidencialidad, integridad y disponibilidad, así como la administración de accesos, respaldo y recuperación.

2. Restricciones

El proyecto no contempla el entrenamiento del modelo desde cero; solo se lleva a cabo la integración e inferencia local de un modelo que ya ha sido entrenado.

- *Interoperabilidad*: A pesar de que se permiten los formatos PNG, JPG, DICOM y TIF la transformación automática a PNG podría conllevar una reducción de la calidad visual, lo cual es notificado al usuario como un impedimento clínico.
- *Perfiles de usuario*: En esta versión solo se contempla el rol del radiólogo, por el momento no hay un módulo para pacientes ni otros perfiles no clínicos.
- *Persistencia*: La versión entregada emplea un manejo temporal de datos, sin guardar longitudinalmente los historiales clínicos.

- *Despliegue*: El sistema fue creado para funcionar de manera controlada en la nube privada (Google Cloud), con la posibilidad de empaquetarse usando Docker Compose para ambientes institucionales locales.
- *Usabilidad*: Necesita un navegador actualizado y una conexión estable, la experiencia de usuario podría verse perjudicada si se cuenta con hardware que no está actualizado.
- *Rendimiento*: El hardware disponible determina la latencia del modelo, la versión más reciente asegura un desempeño apropiado en equipos de gama media-alta.
- *Disponibilidad*: Los mecanismos de alta disponibilidad y recuperación ante desastres todavía no se han implementado a pesar de que la arquitectura es escalable.

3. Especificación Funcional

Cada funcionalidad incluye los requerimientos más importantes que hacen posible que se ejecute correctamente el flujo de análisis de mamografías.

3.1 Funcionalidad: Carga de estudios mamográficos.

El sistema posibilita que el usuario suba estudios de mamografía en varios formatos, los cuales serán analizados posteriormente con la ayuda del modelo de inteligencia artificial. Esta es la característica básica del flujo de diagnóstico.

Requisitos relacionados:

- Recibir archivos en formato DICOM, PNG y JPG.
- Validar la integridad del archivo antes de procesarlo (si el modelo no es capaz de soportarlo de manera nativa, transformar DICOM a Figura y mostrar advertencias).
- Habilitar la carga de 1 a 4 vistas (L-CC, R-CC, L-MLO y R-MLO).
- Indicar el estado de la carga (si ha tenido éxito, si se ha producido un error o si está en progreso).
- Documentar temporalmente la metadata de la investigación para el informe.

3.2 Funcionalidad: Visualización e interacción con imágenes.

Mediante un visor especializado basado en Cornerstone, la aplicación posibilita que el usuario examine las mamografías subidas antes y después del análisis automático.

Requisitos relacionados:

- Visualización de imágenes con alta resolución.
- Herramientas de interacción:
 - Zoom continuo.
 - Regulación de contraste/brillo.
 - Inversión de colores.
- Transición entre vistas (L-CC, R-CC, L-MLO, R-MLO).
- Asegurar una reacción fluida a las acciones del usuario.
- Conservar la coherencia visual entre las imágenes originales y las modificadas.

3.3 Funcionalidad: Clasificación automática de BI-RADS.

El sistema facilita el envío de imágenes preprocesadas al backend para conseguir una predicción de la clasificación BI-RADS a través del modelo ResNet-18 ajustado.

Requisitos relacionados:

- Preprocesamiento automático (normalización, redimensionado, RGB y CLAHE si corresponde).
- Remisión del tensor multivista al modelo.
- Obtención de probabilidades para las categorías BI-RADS 1 a 5.
- Distribución de la última clase según la probabilidad más alta.
- Se guarda el resultado para que pueda ser visualizado y exportado.
- Tiempo de respuesta aceptable desde un punto de vista clínico (<15 s en CPU).
- Gestión de errores de inferencia.

3.4 Funcionalidad: Visualización de resultados de análisis.

Los resultados entregados por el modelo de inteligencia artificial se muestran en la interfaz de una manera clara y fácil de ver.

Requisitos relacionados:

- Presentar la categoría final de BI-RADS.
- Representar gráficamente la probabilidad por cada clase (con gráficos de tipo donut).
- Cuando esté disponible, exhibir la predicción por vista.

- Indicar la clase que más sospecha genera.
- Señalar que el resultado es una asistencia diagnóstica y no un diagnóstico clínico definitivo.
- Dejar que el usuario haga comentarios de tipo clínico.

3.5 Funcionalidad: Generación de reportes de análisis.

El sistema posibilita la recopilación de la información del estudio (incluyendo imágenes, resultados BI-RADS, probabilidades y notas) en un archivo que se puede descargar.

Requisitos relacionados:

- Generación automática de un archivo PDF.
- Incorporación de miniaturas de las imágenes subidas.
- Incorporación de los resultados por clase y la categoría final.
- Incorporación de información fundamental del estudio (cédula, fecha y usuario).
- Facilitar que el documento se descargue de manera local.
- Eliminar datos temporales después de la creación del informe para garantizar la privacidad.

3.6 Funcionalidad: Gestión de usuarios y autenticación.

El sistema asegura la confidencialidad y trazabilidad al establecer control de acceso a través de un sistema de autenticación.

Requisitos relacionados:

- Registro de usuarios (administrador).
- Inicio a la sesión a través de JWT.
- Comprobación automática de la validez del token y de su caducidad.
- Actualización de la contraseña y modificación del perfil básico.

3.7 Resumen de requerimientos funcionales

ID	Requerimiento funcional
RF-01	Cargar los estudios mamográficos en DICOM/TIF/JPG/PNG.
RF-02	Comprobar la integridad de los archivos cargados.
RF-03	Realizar la respectiva conversión de DICOM cuando sea necesario.

- RF-04 Visualizar las imágenes en el visor cornerstone.
- RF-05 Permitir hacer zoom, cambiar brillo/contraste e invertir colores.
- RF-06 Ejecutar clasificación BI-RADS mediante el modelo ResNet-18.
- RF-07 Mostrar la probabilidad por clase y categoría final.
- RF-08 Mostrar los gráficos de los resultados.
- RF-09 Mostrar las predicciones por vista cuando aplique.
- RF-10 Generar el reporte PDF con resultados del análisis.
- RF-11 Permitir la descarga del reporte.
- RF-12 Gestionar los usuarios mediante autenticación JWT.
- RF-13 Registrar la actividad básica para trazabilidad del sistema.

III- DISEÑO DE LA SOLUCIÓN

4. Arquitectura general del sistema

El sistema fue creado usando una arquitectura de cliente-servidor modular de tres capas fundamentales, con el objetivo de asegurar la división de responsabilidades, la escalabilidad y el mantenimiento, este diseño fue establecido con base en los requisitos del SRS y fue registrado de manera oficial en el Software Design Document (SDD).

- *Capa de presentación (Frontend)*: Fue desarrollada con Angular 17 y utiliza el patrón SPA (Single Page Application), lo que posibilita una navegación reactiva y fluida, el diseño tuvo en cuenta la interacción del usuario médico con las imágenes y los resultados del modelo, enfocándose en la claridad visual y la usabilidad clínica.
- *Capa de lógica de negocio (Backend)*: Fue desarrollada en FastAPI (Python) con base en los fundamentos de la arquitectura REST, y se encarga de validar datos, controlar el acceso y comunicarse con el modelo de inteligencia artificial.
- *Capa de datos e inferencia*: Fue creada para incorporar un modelo CNN preentrenado (ResNet-18), que brinda soporte para la administración temporal de datos en una base PostgreSQL.
- *Infraestructura de despliegue*: se desarrolló una táctica fundamentada en contenedores Docker que son orquestados con Docker Compose, lo que asegura aislamiento y portabilidad entre los servicios.




Figura 1: Modelo MVC

Diagrama BPMN

El siguiente diagrama describe el proceso que debe realizar un radiólogo para analizar mamografías. El sistema está enfocado en apoyar las tareas de análisis y archivación de resultados.




Figura 2: Diagrama BPMN

Arquitectura de alto nivel

El diagrama muestra el sistema de clasificación automatizada de mamografías según la escala BI-RADS donde el Usuario Radiólogo interactúa con cinco funcionalidades principales conectadas a una Base de Datos MySQL central.

El flujo comienza obligatoriamente con Registro y Autenticación que valida el acceso del usuario. Una vez autenticado, puede acceder a Gestión de Usuario para administrar su perfil.

Las funcionalidades operativas incluyen: Carga y Validación de Imágenes donde se suben las mamografías, Análisis de Clasificación que utiliza un modelo de IA de Hugging Face para generar clasificaciones BI-RADS, y Listado de Reportes que consulta el historial de diagnósticos almacenados.

Todos los datos fluyen hacia y desde la base de datos central, mientras que el procesamiento de inteligencia artificial se realiza mediante el modelo externo de Hugging Face. El sistema garantiza que solo usuarios autenticados puedan acceder a las funcionalidades y la información médica.





Figura 3: Arquitectura de alto nivel

Diagrama de despliegue

El sistema se encuentra desplegado por medio de Google Cloud, el frontend, backend y base de datos se encuentran almacenados en un Docker ejecutado dentro de una máquina virtual, al cual se conecta el usuario desde su navegador. El modelo de clasificación, alojado en Huggingface, es accedido por medio de peticiones creadas por el Backend.



Powered By Visual Paradigm Community Edition

Figura 4: Diagrama de despliegue

5. Diseño Funcional

La forma en que los diferentes elementos del sistema interactúan para satisfacer las especificaciones establecidas en el SRS fue determinada gracias al diseño funcional. Este diseño se ilustró a través de diagramas UML de flujo de datos, secuencia y casos de uso, que se utilizaron como fundamento para la implementación, el sistema fue diseñado como una plataforma modular, en la que cada función principal está orientada a un objetivo técnico o clínico particular. En general, estos módulos aseguran que la información sea rastreada desde el momento en que se cargan las imágenes hasta que se elabora el informe final en pdf.

5.1 Estructura funcional general

- *Autenticación y control de acceso:* Estructurado como un módulo de entrada, con verificación de credenciales a través de tokens. Este diseño garantiza que el acceso permanezca íntegro y que los privilegios estén separados.
- *Gestión de imágenes médicas:* Establece el procedimiento para cargar y validar archivos en formato DICOM, TIF, JPG, PNG. El diseño sigue un proceso de verificación de formato y conversión a PNG, pues el modelo no procesa DICOM de manera nativa.
- *Procesamiento e inferencia con Inteligencia Artificial:* Es el núcleo operativo del sistema, el flujo determina la comunicación entre el modelo CNN (ResNet-18) y el backend, gestionando las funciones de clasificación BI-RADS (1 a 5).
- *Visualización de resultados:* Se creó un módulo para mostrar los resultados que utiliza tablas de probabilidad y gráficos (donut charts), su propósito es ofrecerle al usuario clínico una perspectiva uniforme y comprensible de los resultados.
- *Generación de reportes:* El diseño establece un procedimiento para afianzar los resultados y crear un documento PDF organizado que contenga datos del estudio, imágenes en miniatura y observaciones del radiólogo

5.2 Diseño Funcional

Los diagramas del SDD ilustran el flujo lógico general y cómo los actores (usuario, backend, modelo de IA y base de datos) interactúan:

- El usuario autenticado inicia sesión.
- Sube las imágenes e inicia el proceso de análisis.

- El modelo de IA recibe la información desde el backend y devuelve las probabilidades BI-RADS.
- La información se envía de vuelta a la capa de presentación para que sea visualizada y se genere el PDF.




Figura 5: Diagrama de flujo

5.3 Módulos de soporte

- *Auditoría y trazabilidad:* Registro cronológico de las acciones del usuario.
- *ConFiguración:* Ajuste de los parámetros del modelo o renovación de componentes sin interrumpir la función principal.
- *Validación y notificación:* Administración de avisos de conexión o formato y mensajes de error.

6. Diseño de la interfaz de usuario

La interfaz de usuario fue diseñada para que el personal médico pudiera interactuar con el sistema siguiendo los principios de simplicidad funcional y consistencia visual, cada vista fue creada en la herramienta de prototipado y después se replicó en Angular 17 a lo largo de la implementación.

Los mockups más importantes que orientaron el desarrollo del sistema se muestran a continuación:



Figura 6: Mockup Pantalla Principal

La pantalla principal sirve como un punto de acceso para el sistema, muestra el nombre de la institución, un mensaje de bienvenida y un botón que remite al usuario al módulo de análisis de mamografías. el diseño hace énfasis en el contraste visual y la claridad. El propósito fue brindar una interfaz sencilla, moderna y directa que permitiera al radiólogo comenzar el flujo de trabajo sin pasos innecesarios.




Figura 7 Mockup Interfaz de Carga de Estudios

Esta vista corresponde al formulario en el que el usuario sube las imágenes asociadas a las cuatro proyecciones estándar:

- L-CC (Cráneo-Caudal por la izquierda)
- R-CC (Cráneo-Caudal de la derecha)
- L-MLO (Oblicua izquierda media-lateral)
- R-MLO (Medio-Lateral Derecha Oblicua)

El diseño incluye un botón único, "Analizar imágenes médicas", que concentra la acción principal y prevé validaciones automáticas de formato, el objetivo de la disposición simétrica de los campos es preservar un orden cognitivo y una ergonomía visual.




Figura 8: Mockup Pantalla de análisis

Esta vista muestra la situación intermedia del sistema mientras se procesan las imágenes, el diseño tiene un mensaje informativo ("Analizando imágenes...") y un indicador de progreso animado que le avisa al usuario que el sistema está llevando a cabo la inferencia del modelo de inteligencia artificial, el objetivo es conservar la retroalimentación visual y evitar que el sistema sea percibido como inactivo mientras se realiza la inferencia del modelo.




Figura 9: Mockup Resultados y gráficas

Los resultados del análisis son presentados en esta vista, clasificados según la perspectiva anatómica, donde cada sección contiene:

- Figura procesada.
- Porcentaje de probabilidad vinculado con la categoría BI-RADS.
- Gráficas de tipo donut chart que muestran la probabilidad de distribución.

El diseño permite una interpretación visual y rápida de los resultados, resaltando la categoría con mayor probabilidad. Adicionalmente, se incluye un botón para descargar el informe y una sección de texto para las observaciones del radiólogo.




Figura 10: Mockup Visor de imágenes médicas

El visor especializado se creó utilizando la biblioteca Cornerstone.js, lo que posibilita al usuario emplear tres herramientas interactivas, el ajuste de brillo y contraste, la inversión de tonalidades y el acercamiento de la Figura, este módulo atiende a las necesidades auténticas de los radiólogos, quienes necesitan trabajar con las imágenes para examinar características de densidad o la existencia de lesiones. El diseño da preferencia a un fondo neutral con íconos nítidos y controles fáciles de usar en la parte superior del visor.




Figura 11: Mockup Reporte en PDF

El reporte en PDF está diseñado de manera que los resultados de la clasificación se presenten formal y estructuradamente, este contiene:

- Encabezado que la información general.
- Clasificación más alta de BI-RADS en el análisis.
- Tabla de resultados según la vista (L-CC, R-CC, L-MLO, R-MLO).
- Miniaturas de las imágenes que fueron procesadas.
- Gráficos de probabilidad.
- Espacio para la rúbrica del radiólogo y observaciones.

El diseño sigue las pautas de documentación médica y trazabilidad, manteniendo un formato profesional y adecuado para su archivo clínico.

7. Diseño lógico y de componentes

El diseño funcional del sistema mantiene una estructura de tipo Model-View-Controller (MVC):

- *Modelo (Model)*: Elementos de Python que se ocupan de la inferencia del modelo de IA y del tratamiento de datos que entran y salen.
- *Vista (View)*: elementos de Angular que muestran la información y posibilitan la interacción del usuario.
- *Controlador (Controller)*: lógica de FastAPI que se encarga de manejar las solicitudes REST, validar las entradas y organizar las respuestas.

El diseño modular permite que el modelo de inteligencia artificial pueda ser reemplazado en el futuro, también que se incorporen nuevos modos (como la resonancia o la ecografía), y que el sistema mantenga su evolución.




Figura 12: Diagrama de clases

8. Selección y justificación de herramientas

Se llevó a cabo una selección de herramientas a través de un análisis técnico comparativo que tuvo en cuenta la licencia libre, el rendimiento, la curva de aprendizaje y la compatibilidad con el sistema.

Componente	Alternativas consideradas	Seleccionada	Justificación
------------	---------------------------	--------------	---------------

Framework Frontend	React, Vue.js, Angular	Angular 17	Soporte SPA, modularidad, estabilidad y experiencia previa del equipo.
Framework Backend	Flask, Django, FastAPI	FastAPI	Mayor velocidad, cuenta con validación automática con Pydantic, integración natural con Python y con modelos de IA.
Modelo de IA	DenseNet121, EfficientNet-B0, ResNet-18	ResNet-18 (Enterwar99)	Modelo que está validado clínicamente, con balance entre precisión y costo computacional.
Base de datos	MySQL, PostgreSQL, SQLite	PostgreSQL	Tiene mejor manejo de concurrencia y seguridad para entornos clínicos.
Infraestructura	AWS, Heroku, Google Cloud	Google Cloud VM + Docker Compose	Capacidad de control total sobre los datos, con ejecución local segura y portabilidad multiplataforma.

Tabla 3: Selección y justificación de herramientas

9. Tecnologías de apoyo

Se utilizaron las tecnologías adicionales que se enumeran a continuación, además del stack principal:

- *Cornerstone.js*: biblioteca dedicada a la visualización de imágenes médicas en navegadores web.
- *Chart.js*: creación de gráficos circulares para los resultados de BI-RADS.
- *SQLAlchemy*: ORM para la comunicación entre PostgreSQL y FastAPI.
- *pydicom* y *OpenCV*: preprocesamiento de imágenes antes de la inferencia.
- Control de acceso y autenticación: OAuth2 y JWT.
- *ReportLab*: creación de informes PDF que contienen información clínica organizada.
- *Docker Compose*: empaquetar y desplegar la base de datos, el backend y el frontend en contenedores independientes.

10. Consideraciones de calidad y seguridad

La calidad del software y la seguridad de la información se encargaron de guiar el diseño, los mecanismos de seguridad que se han puesto en marcha son:

- Autenticación utilizando tokens JWT.
- Bcrypt para el cifrado de contraseñas.
- Comprobación de los formatos de archivo antes de la carga.
- Limitación del acceso a las funciones de acuerdo con el rol.
- Implementación en una red privada o máquina virtual controlada.

11. Resumen del diseño

El diseño del sistema determinó la estructura funcional y técnica que se requería para incorporar un modelo de inteligencia artificial en la clasificación automática de mamografías según la escala BI-RADS. Se implementó una estructura modular que se apoya en el patrón Modelo-Vista-Controlador (MVC), lo que posibilitó la división de responsabilidades entre la interfaz de usuario (Angular), la lógica del negocio (FastAPI) y el modelo de inferencia (ResNet-18).

La funcionalidad del diseño estableció los flujos de interacción desde que se autentica hasta que se genera el informe en PDF, asegurando la trazabilidad y la facilidad de uso en la gestión de datos clínicos. Los mockups de interfaz fueron utilizados para comprobar la experiencia del usuario, la organización visual y la navegación antes de llevar a cabo la implementación.

Se eligieron como herramientas Angular, FastAPI, PostgreSQL y Docker Compose debido a su estabilidad, compatibilidad y soporte abierto que garantiza que la ejecución sea segura, escalable y portátil.

En conclusión, el diseño ofreció una base firme para la puesta en marcha del sistema, fusionando criterios de ingeniería con ética médica y salvaguarda de datos en una solución que es flexible y mantenible.

IV- DESARROLLO DE SOLUCIÓN

La solución se desarrolló de acuerdo con lo planteado en la fase de planificación basada en el método ágil Scrum, este proceso fue organizado en sprints iterativos que incluyeron las etapas de diseño, implementación, integración y validación del sistema, asegurando la trazabilidad entre los requisitos especificados en el SRS y las características ofrecidas en el producto final.

Cada sprint posibilitó la creación de manera incremental de los elementos esenciales: interfaz de usuario (frontend), API de backend, módulo de inteligencia artificial, base de datos, y contenedores de despliegue, las decisiones sobre el diseño y la implementación se basaron en lo establecido dentro del SDD (Software Design Document).

1. Metodología de desarrollo

El sistema fue desarrollado siguiendo un enfoque ágil basado en Scrum que posibilitó dividir el trabajo en sprints o iteraciones cortas, donde cada uno de los sprint duró alrededor de una semana y concluyó con un entregable, ya sea funcional o documental, que iba mejorando la solución de manera progresiva.

Esta perspectiva posibilitó mantener una comunicación continua con la directora del proyecto, además de validar las decisiones técnicas desde el inicio y asegurar que hubiera trazabilidad entre los requerimientos establecidos en el SRS y los resultados alcanzados, *ClickUp* fue la herramienta usada para planificar, donde se manejaron los registros de progreso, las historias de usuario, las tareas de cada sprint y el product backlog.

Para consolidar las versiones estables del sistema, el repositorio de GitHub del proyecto fue la fuente principal de control de versiones, combinando las ramas Dev y Main.

1.1. Estructura general de trabajo

El ciclo de desarrollo se segmentó en cuatro etapas iterativas principales:

- *Diseño y definición de requisitos*: Creación de especificaciones tanto funcionales como no funcionales, diseño de la arquitectura base y producción de los mockups.
- *Integración del modelo de inteligencia artificial*: Validación técnica del modelo ResNet-18 y desarrollo de la comunicación entre el modelo de inferencia y el backend.

- *Implementación y pruebas funcionales:* Desarrollo de la interfaz utilizando Angular 17, vinculación con FastAPI y validación del flujo total (carga, análisis, informe).
- *Implementación y documentación final:* Empaquetado en Docker Compose con implementación en Google Cloud VM, creación de la memoria final, los manuales y consolidación de anexos.

1.2. Cronología de trabajo por sprints

La siguiente tabla resume todos los sprints pertenecientes al desarrollo del proyecto, los objetivos centrales de cada uno, las metas alcanzadas y la documentación producida en cada fase:

Sprint	Periodo	Objetivo principal	Actividades destacadas
2 (4–10 ago)	Diseño visual y autenticación	- Diseño de mockups (Figma) - Definición de requisitos SRS v1 - Implementación de autenticación JWT • Conexión inicial frontend–backend	- SRS versión 1 - Mockups incorporados a la memoria - Módulo de autenticación funcional
3 (11–17 ago)	Validación del modelo IA	- Evaluación del modelo ResNet-18 - Pruebas de precisión y sensibilidad - Documentación de arquitectura IA	- Sección IA en la memoria - Actualización SRS con arquitectura del modelo
4 (18–24 ago)	Diseño técnico y arquitectura	- Diseño cliente–servidor–modelo–BD - Creación de SDD v1 con diagramas UML - Validación con la directora	- SDD versión 1 - Diagramas de arquitectura y procesos en la memoria
5 (25–31 ago)	Flujo mínimo funcional	- Interfaz de carga de imágenes - Validaciones de formato - Primer flujo carga - resultado	- Manual de usuario (versión inicial) - Memoria actualizada con flujo funcional
6 (1–7 sep)	Backend y conexión con IA	- Endpoints FastAPI	- API documentada (Swagger)

		- Comunicación frontend-backend-modelo - Validación de respuesta BIRADS	- Memoria con sección “Interacción con el modelo IA”
7 (8-14 sep)	Visualización y reportes	- Integración Chart.js - Generación PDF (ReportLab) - Gestión de roles y accesibilidad visual	- Reportes de ejemplo - Manual de usuario actualizado
8 (15-21 sep)	Validación UX y control de calidad	- Plan de pruebas clínicas - Formularios de retroalimentación - Correcciones de interfaz	- Plan de validación con radiólogos - Control de calidad v1
9 (22-28 sep)	Pruebas clínicas y mejoras finales	- Pruebas reales con usuarios - Ajustes de interfaz y rendimiento	- Resultados de pruebas - Validación clínica documentada
10-14 (29 sep-2 nov)	Documentación y entrega final	- Consolidación de anexos - Verificación de entregables PUJ - Ensayos de sustentación	- Memoria completa - Manuales y anexos aprobados
15-16 (3-16 nov)	Cierre técnico y formal	- Etiquetado GitHub v1.0-final - Respaldo de archivos y entrega oficial	- Versión final enviada a dirección y coordinación - Acta de entrega

Tabla 4: Cronograma de Sprints

1.3 Resultados de la metodología

Mediante entregables parciales revisados cada semana, el empleo de Scrum permitió un desarrollo iterativo y controlado, donde cada iteración mejoró la funcionalidad del sistema y permitió que se hicieran validaciones en las primeras etapas con la directora, garantizando la calidad del software. Además, esta metodología promovió que el código se integrara de manera constante en GitHub y que la documentación técnica (SRS, SDD, Manual del usuario, Memoria, Anexos) se actualizara continuamente.

La aplicación rigurosa de este método aseguró la consistencia entre el análisis, diseño, implementación y las pruebas, lo que facilitó que los objetivos del proyecto se lograran dentro del cronograma definido.

2. Descripción del sistema en funcionamiento

El sistema final es una plataforma web modular que incorpora un modelo de inteligencia artificial basado en redes neuronales convolucionales (ResNet-18) para categorizar automáticamente las mamografías de acuerdo con la escala BI-RADS (1-5). La aplicación se ejecuta en un entorno Docker Compose, el cual cuenta con servicios para el frontend (Angular), el backend (FastAPI) y la base de datos (PostgreSQL) que pueden estar funcionando localmente o en una máquina virtual proporcionada por Google Cloud.

El flujo operativo inicia con la validación del usuario, sigue con la carga y el estudio de imágenes, y concluye con la presentación de los resultados y la producción del informe clínico en PDF.

A continuación, se explican las pantallas y los componentes fundamentales que integran la versión operativa del sistema.



The image shows a login interface with a light orange background. At the top, the text "Iniciar Sesión" is centered in a bold, black font. Below this, there are two input fields: the first is labeled "Documento" and the second is labeled "Contraseña". Both fields have a light orange border and a small orange icon on the right. Below the input fields is a rounded orange button with the text "Entrar" in black. At the bottom, there is a link that says "¿No tienes cuenta? Registrarte" in orange text, enclosed in a light orange rounded rectangle.

Figura 13: Pantalla de inicio de sesión (login/)

La entrada al sistema se logra a través de la pantalla inicial de inicio de sesión, que permite el acceso mediante credenciales validadas en la base de datos, el diseño incluye la autenticación JWT (JSON Web Token) con acceso total a la carga, evaluación y generación de informes.

Se ejecutaron validaciones de campos y mensajes dinámicos de error.

The screenshot shows a registration form titled "Registrarse". It contains four input fields: "Documento", "Nombre", "Fecha de nacimiento" (with a date picker showing "14/11/2025"), and "Contraseña". Below the fields are two buttons: "Crear cuenta" and "¿Ya tienes cuenta? Inicia sesión".

Figura 14: Pantalla de registro de usuario (register/)

Permite registrar nuevos usuarios de manera controlada, el formulario comprueba si el documento ingresado es único, si la contraseña es segura y si los datos introducidos tienen el formato adecuado. A través de endpoints seguros de FastAPI el flujo de registro se logra vincularse directamente con el backend.

The screenshot shows a web interface titled "Clasificador de Mamografías en Escala BI-RADS". It has a navigation bar with links: "Análisis", "Mi cuenta", "Lista de Reportes", "Información", and "Cerrar Sesión". The main content area has four boxes for selecting and uploading images: "L-CC (Cráneo-Caudal Izquierda)", "R-CC (Cráneo-Caudal Derecha)", "L-MLO (Bólcula Medio-Lateral Izquierda)", and "R-MLO (Bólcula Medio-Lateral Derecha)". Each box contains a "Seleccionar archivo" button and a file input field. Below these are four rows of buttons for uploading specific image types: "L-CC", "L-MLO", "R-CC", and "R-MLO". At the bottom, there is a disclaimer in Spanish and an "Analizar imágenes" button.

Figura 15: Pantalla de carga de imágenes (upload/)

Corresponde al punto de inicio del flujo clínico, donde el usuario tiene la posibilidad de subir mamografías en formatos PNG, JPG o DICOM y TIF, si el modelo de IA no procesa DICOM de manera nativa, el sistema convierte automáticamente a PNG y valida las dimensiones y el formato del archivo, las imágenes cargadas se presentan en miniaturas precedentes organizadas por proyección de la siguiente manera:

- L-CC (Cráneo-Caudal izquierdo)
- R-CC (Cráneo-Caudal hacia la derecha)
- L-MLO (Medio-Lateral de la izquierda)
- R-MLO (Medio-lateral derecho)

Al dar clic en el botón "Analizar imágenes médicas", se inicia la inferencia con el script *predict_resnet_multiview.py*.

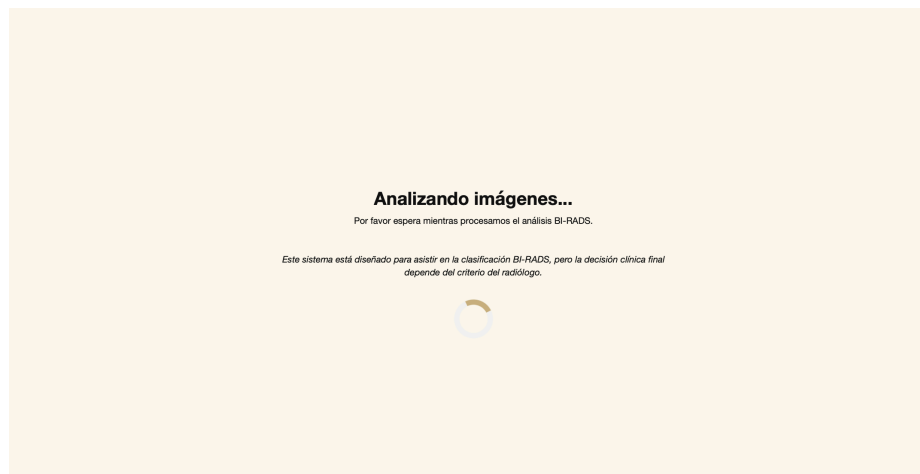


Figura 16: Pantalla de análisis (proceso de inferencia)

En este momento se lleva a cabo el procedimiento de inferencia del modelo de inteligencia artificial, la parte central del sistema, después de cargar las imágenes y validar el análisis se hace una petición POST al endpoint `/predict_multiview/` del backend FastAPI desde el frontend, donde el script *predict_resnet_multiview.py* procesa la información.

Las imágenes se preprocesan (se normalizan, se convierte a escala de grises, se les mejora el contraste mediante CLAHE y se recorta la ROI), luego se agrupan en un tensor multivista con las cuatro proyecciones estándar (R-CC, R-MLO, L-CC y L-

MLO) y finalmente son enviadas al modelo ResNet-18 que está incorporado en el contenedor, a través de una capa softmax, el modelo crea un vector de probabilidades para cada categoría BI-RADS (1-5), y sus resultados se retornan al frontend en formato JSON.

La interfaz presenta una barra de progreso animada que refleja el estado del procesamiento y evita la impresión de inactividad durante el análisis, los resultados se presentan de manera automática en la pantalla de resultados después de que la inferencia ha sido completada. En una CPU de gama media, los tiempos promedio de respuesta para cada estudio son entre 30 y 60 segundos (dependiendo de la calidad y el formato de las imágenes).






Figura 17: Pantalla de resultados (report/)

En este componente se muestran los resultados alcanzados del modelo, clasificados por proyección (L-CC, R-CC, L-MLO, R-MLO).

Cada uno de los resultados incluye:

- Las imágenes examinadas.
- Porcentajes de probabilidad por cada categoría BI-RADS.
- Un gráfico de tipo pastel creado con Chart.js.
- Un texto que destaca la categoría más elevada del análisis.

El usuario tiene la posibilidad de incluir observaciones clínicas y crear el informe PDF con un solo clic, los resultados no se guardarán de manera permanente con el fin de mantener la privacidad del paciente.




Figura 18: Visor de imágenes médicas (visor-cornerstone/)

Se usó Cornerstone.js para crear el visor especializado, lo que posibilita al radiólogo llevar a cabo un análisis visual más exacto, donde se incluyen las siguientes herramientas puestas en práctica:

- Control de la luminosidad y el contraste.
- Inversión de colores.
- Zoom interactivo a través de la rueda del mouse o el control deslizante.

Para asegurar una experiencia ergonómica de usuario, el diseño prioriza un fondo neutro, iconos clínicos universales y controles que sean fácilmente accesibles.

Reporte de Análisis BI-RADS

Categoría	Interpretación breve
BI-RADS 1	Negativo
BI-RADS 2	Hallazgos benignos
BI-RADS 3	Probablemente benigno (<2%)
BI-RADS 4	Sospechoso, biopsia recomendada
BI-RADS 5	Altamente sugestivo de malignidad

BI-RADS Dominante: BI-RADS 3

Clasificación por Vista

Cráneo-Caudal Izquierda: **BI-RADS 3 (85,52%)**

Cráneo-Caudal Derecha: **BI-RADS 1 (80,09%)**

Observaciones del Radiólogo:

Se observan densidades focales de bordes bien definidos en la proyección cráneo-caudal izquierda (L-CC), sin evidencia clara de espículas, retracciones cutáneas ni distorsiones de la arquitectura mamaria. No se identifican microcalcificaciones agrupadas ni masas de características sospechosas en esta proyección. La distribución de la densidad es simétrica y no se aprecian asimetrías nuevas ni cambios significativos con respecto a controles previos (si disponibles).

En la proyección R-CC, la mamografía presenta parénquima mamario sin alteraciones estructurales evidentes. La densidad observada es compatible con tejido fibroglandular sin hallazgos patológicos.

Dado el alto valor probabilístico asignado por el sistema a BI-RADS 3 en la imagen L-CC (85.52%), se sugiere seguimiento en 6 meses para descartar progresión o evolución de las características morfológicas del hallazgo.

Las imágenes procesadas junto a su análisis se mostrarán a continuación

El sistema actúa como herramienta de apoyo para la toma de decisiones clínicas, no como diagnóstico definitivo.

Figura 19: Reporte descargable en PDF

El sistema produce de manera automática un informe estructurado en PDF que contiene:

- Versiones reducidas de las imágenes analizadas.
- Clasificación BI-RADS más elevada.
- Gráficos de probabilidad por perspectiva.
- Campo para la firma digital y las observaciones del radiólogo.

El informe se descarga en el dispositivo del usuario, sin ser enviado a servidores externos, cumpliendo con la protección de datos personales.




Figura 20: Componente de información (info/)

Este módulo ofrece datos institucionales acerca del sistema, incluyendo su finalidad, metodología, recomendaciones sobre y para su uso y aspectos éticos.

Figura 21 Componente de perfil (perfil/)

Facilita al usuario cambiar su contraseña y modificar sus datos personales, en este componente se llevan a cabo comunicaciones con el backend a través de endpoints seguros, lo que asegura la protección de los datos.



FECHA Y HORA	BI-RADS DOMINANTE	DETALLES	ACCIONES
06/11/2025, 05:08	BI-RADS 4	Ver Detalles	Descargar PDF

Figura 22: Componente de reportes (reportes/)

Proporciona una perspectiva consolidada de los informes producidos en la sesión actual, su objetivo es posibilitar la verificación local y la rápida revisión de los resultados sin tener que cargar nuevamente los archivos originales.

3. Componentes adicionales

El sistema tiene, además de las interfaces principales ya mencionadas, diversos elementos internos y de soporte técnico que aseguran su adecuado desempeño, aunque el usuario final no puede ver estos módulos, son fundamentales en el flujo de operación general del sistema.

11.1 Backend y control de servicios (FastAPI)

Se utilizó FastAPI (Python 3.10) para implementar el backend, que está basado en una arquitectura REST y con módulos autónomos para la gestión de archivos, la inferencia, la generación de reportes, el procesamiento de imágenes y la autenticación. Su estructura modular posibilita una integración adaptable y favorece el mantenimiento.

Los módulos más significativos incluyen:

- auth/: Administra la autorización y autenticación por medio de tokens web en formato JSON (JWT); establece roles de usuario y protege los endpoints.

- routes/: Alberga las rutas más importantes del sistema, que incluyen /upload, /predict_multiview/ y /generate_report.
- models/: Establece las clases ORM (SQLAlchemy) para las tablas de usuarios, permisos y registros temporales.
- services/: Engloba la lógica empresarial que une las rutas con los procedimientos de IA, el preprocesamiento de imágenes y la creación de archivos.
- utils/: Contiene funciones de apoyo para la gestión de errores, la validación de archivos y las operaciones de conversión entre DICOM y PNG

Además, el backend produce la documentación automática de la API utilizando Swagger/OpenAPI, lo que simplifica el proceso de validación y prueba de los endpoints a lo largo del desarrollo.

11.2 Base de datos (PostgreSQL)

Para manejar los usuarios, los roles, la autenticación y el control de sesiones, el sistema utiliza una base de datos PostgreSQL, su diseño es ligero y está enfocado en la gestión temporal de datos, evitando almacenar información clínica sensible de imágenes o resultados.

Las tablas más importantes son:

Tabla	Propósito
users	Almacena credenciales, roles y metadatos de cada usuario.
roles	Define permisos y jerarquías de acceso (admin, radiólogo, técnico).
sessions	Registra tokens activos y tiempos de expiración de sesión.
logs	Guarda eventos temporales de carga, inferencia o descarga de reportes para trazabilidad.

Tabla 5: Tablas de la base de datos

La gestión del acceso a la base de datos se lleva a cabo por medio de SQLAlchemy ORM, lo cual posibilita ejecutar operaciones CRUD eficaces y seguras.

11.3 Módulo de almacenamiento temporal de archivos

En el proceso de análisis, las imágenes que se cargan y los informes producidos se guardan de forma momentánea en carpetas supervisadas dentro del contenedor backend, después de que se ha terminado el proceso de clasificación y se ha descargado

el informe en PDF, estos archivos se suprimen automáticamente para proteger la confidencialidad de los datos médicos.

Este flujo se ajusta a lo indicado en relación con la protección de datos personales, pues no mantiene información delicada por más tiempo del estrictamente necesario para el análisis.

11.4 Módulo de generación de reportes (ReportLab)

El sistema emplea la biblioteca ReportLab para generar informes en formato PDF, este módulo obtiene los resultados que el modelo devuelve, así como la información del paciente, las imágenes en miniatura y los gráficos de probabilidad.

El documento final incluye:

- Encabezado institucional.
- Clasificación BI-RADS más alta del análisis.
- Miniaturas de las imágenes examinadas.
- Porcentajes de probabilidad.
- Lugar para observaciones de tipo médico.

El informe se crea en el servidor y se envía al frontend para que el usuario lo descargue de manera inmediata.

11.5 Módulo de auditoría y registro

El sistema cuenta con un módulo de auditoría ligera que se encarga de documentar los eventos más importantes durante la sesión del usuario:

- Accesos que tuvieron éxito y los que no.
- Subida de archivos.
- Realizaciones de inferencia.
- Generaciones de reportes.

Estos registros se guardan en la tabla logs y se borran de manera periódica, siguiendo las políticas de confidencialidad establecidas para el sistema.

4. Despliegue y validación

El sistema se integra por tres contenedores primordiales, los cuales están especificados en el archivo docker-compose.yml del repositorio:

4.1 Arquitectura de despliegue

Servicio	Descripción	Puerto	Tecnología
frontend	Contenedor Angular con la interfaz web clínica.	4200	Node.js / Angular 17
backend	API REST implementada en FastAPI; contiene el modelo IA.	8000	Python 3.10 / FastAPI / Uvicorn
db	Base de datos para gestión de usuarios y roles.	5432	PostgreSQL 14

Tabla 6: Despliegue de cada componente

Las rutas externas (puertos 4200 y 8000) se exponen solo para permitir el acceso controlado desde la API y el navegador, pero la comunicación entre los servicios se realiza a través de una red interna de Docker.

El script *predict_resnet_multiview.py*, el modelo ResNet-18 y las dependencias de procesamiento (OpenCV, PyTorch, pydicom) se encuentran en el contenedor del backend. FastAPI proporciona los endpoints que el frontend Angular utiliza para la carga de imágenes, la visualización avanzada a través de Cornerstone.js, la inferencia, la generación de informes y la autenticación.

4.2 Despliegue en Google Cloud

El sistema se implementó en una máquina virtual de Google Cloud con la siguiente configuración:

- Sistema operativo: Ubuntu 22.04 versión de soporte a largo plazo
- Memoria RAM: 8 gigabytes
- CPU: Cuatro vCPUs
- Capacidad de almacenamiento: 100 GB en SSD
- Conexión: Red privada con acceso a través de SSH
- Gestión de contenedores: Docker Compose + Docker Engine

La aplicación se ejecuta como un servicio persistente que comienza de manera automática cuando la instancia es iniciada, el acceso se lleva a cabo por medio de una IP estática que posibilita la conexión al frontend a través del navegador y al backend mediante endpoints REST seguros.

El sistema logró un rendimiento estable tanto en el entorno local como en la nube, asegurando que la totalidad del flujo de trabajo sea consistente: iniciar sesión, cargar, inferir, obtener resultados, visualizar, reportar.

Los ensayos de validación comprobaron que el prototipo satisface todos los propósitos técnicos y funcionales establecidos, estableciéndose como una solución segura, reproducible y capaz de adaptarse a situaciones clínicas reales.

5. Modelo de inteligencia artificial integrado

El sistema incluye un modelo de clasificación BI-RADS que se basa en una arquitectura ResNet-18 adaptada (fine-tuned) a imágenes mamográficas, este modelo se obtuvo desde el repositorio público de HuggingFace llamado MODEL_MAMMOGRAFI del autor (usuario) Enterwar99, y contiene una capa final alterada para generar cinco categorías BI-RADS (1-5).

5.1. Arquitectura y parámetros

El modelo conserva la estructura fundamental de ResNet-18 y sustituye su última capa por:

```
nn.Sequential(  
    nn.Dropout(0.5),  
    nn.Linear(512, 5)  
)
```

Los parámetros de entrenamiento originales fueron los siguientes:

- *Épocas*: 25
- *Tasa de aprendizaje*: 1×10^{-4}
- *Optimizador*: Adam

- *Función de pérdida:* CrossEntropyLoss
- *Augmentaciones:* volteo horizontal, rotación, recorte centrado, normalización
- *Tamaño de entrada:* 224×224 px
- *Normalización:* media y desviación estándar de Figuraet

5.2. Datos esperados por el modelo

- *Entrada:* imágenes mamográficas convertidas a RGB normalizadas y redimensionadas.
- *Salida:* vector de probabilidades softmax para BI-RADS 1–5.

Durante la inferencia, el backend procesa las imágenes (DICOM, TIF, PNG, JPG) mediante conversión, normalización y reescalado antes de enviarlas al modelo.

5.3. Integración dentro del backend

El modelo ResNet-18 se incluyó en un flujo estructurado para permitir la inferencia de forma estable y segura, esta integración fue hecha en el backend que fue creado con FastAPI. La lógica de preprocesamiento, la ejecución del modelo, el ensamblaje de vistas y el postprocesamiento de resultados se encuentra principalmente en el módulo *predict_resnet_multiview.py*. Las etapas que componen el flujo técnico de integración son las siguientes:

- *Carga del modelo y preparación del entorno*

Cuando inicia el contenedor del backend, el modelo ResNet-18 se integra desde Hugging Face al repositorio y se carga en memoria usando PyTorch, esta acción se lleva a cabo una sola vez y posibilita que las futuras peticiones de inferencia se realicen sin volver a cargar el modelo, lo cual disminuye la latencia, el backend configura los transformadores de entrada con normalización de Figuraet, la estructura del modelo con su capa final ajustada y la política de evaluación, garantizando que no se modifiquen los pesos en tiempo de ejecución.

- *Recepción de imágenes y validación*

El backend obtiene las cuatro proyecciones estándar de un estudio mamográfico mediante el endpoint *predict_multiview*, las imágenes pueden presentarse en DICOM,

TIF, PNG o JPG, esta fase ejecuta la validación del tipo de archivo, la conversión de DICOM a matriz numpy mediante pydicom y el manejo de errores en caso de que algún archivo esté corrupto, incompleto o en un formato no soportado, asegurando robustez y evitando fallos en la inferencia.

- *Preprocesamiento y ensamblaje multivista*

Antes de que las imágenes se envíen al modelo, se realiza un preprocesamiento que incluye:

- Duplicación de canales y conversión a escala de grises para lograr una Figura RGB.
- Conforme a las especificaciones del dataset original, se realiza una normalización de los valores entre 0 y 1.
- Recorte focalizado, que se basa en Otsu o ROI detectada.
- Redimensionamiento a la resolución requerida: 224×224 píxeles.
- Empleo de métodos como CLAHE para optimizar el contraste.

Después de este proceso, las cuatro vistas (L-CC, R-CC, L-MLO y R-MLO) se disponen en un tensor con la siguiente forma

$(1, 4, 224, 224)$

- *Ejecución de la inferencia*

El modelo ResNet-18 se sostiene con el tensor multivista y genera un vector de logits que, a través de softmax, se transforma en probabilidades de la siguiente manera:

$[p(BI-RADS\ 1), p(2), p(3), p(4), p(5)]$

Este procedimiento demora en promedio entre 5 y 10 segundos en el CPU, lo cual se mantiene dentro del rango clínico razonable para flujos asistidos por inteligencia artificial.

- *Postprocesamiento y retorno de resultados*

Finalmente, el backend convierte los resultados a formato JSON, calcula la clase de mayor probabilidad, adjunta los metadatos relevantes como la resolución, la orden de

vistas y la hora del análisis y por último envía la respuesta al frontend para su visualización y para la generación del PDF. Este flujo permite mantener una separación clara entre la inferencia (PyTorch), la lógica de negocio (FastAPI) y la presentación en Angular, lo cual fortalece la mantenibilidad del sistema bajo el patrón MVC.

6. Conclusiones del desarrollo

El desarrollo del sistema posibilitó la creación de una plataforma web segura y funcional para clasificar automáticamente mamografías de acuerdo con la escala BI-RADS (1-5), incorporando un modelo de inteligencia artificial en un flujo clínico integral.

El empleo de la metodología ágil (Scrum) permitió un avance en iteraciones, con entregas que se podían verificar y una congruencia entre los requerimientos, el diseño y la ejecución, se pudo crear una arquitectura modular, que puede ser escalada y desplegada de manera sencilla en ambientes locales o en la nube gracias a las tecnologías elegidas: Docker Compose, PostgreSQL, Angular y FastAPI.

El modelo ResNet-18 se incorporó de manera estable en el backend, logrando tiempos de inferencia apropiados desde el punto de vista clínico y resultados coherentes, el uso de Google Cloud para el despliegue permitió la portabilidad y la protección de los datos confidenciales.

En resumen, la solución creada cumple con los objetivos técnicos y funcionales planteados, estableciéndose como una herramienta factible, reproducible y que puede ser adaptada para brindar soporte diagnóstico en contextos clínicos reales.

V- RESULTADOS

Con el fin de asegurar la calidad del software, se realizaron pruebas unitarias, de carga, de seguridad y de aceptación del sistema. A continuación, se presentan los resultados obtenidos por cada prueba, información más detallada sobre estas se encuentra en los documentos anexos Pruebas de Software y Documento de Pruebas.

Unitarias

Se realizaron un total de 10 pruebas unitarias en diferentes puntos del desarrollo del sistema para evaluar sus funciones, tales como cuentas de usuario, carga de imágenes,

tiempo de respuesta y descarga de reportes PDF. Para el final del proceso, 8 pruebas fueron aprobadas satisfactoriamente mientras que 2 fueron aprobadas con errores menores. Las dos pruebas aprobadas con errores son:

- Descarga de reportes anteriores: los reportes anteriores no incluyen graficas, pero si incluyen las imágenes mamográficas y la información más importante del análisis.
- Precisión del modelo: El modelo es más preciso al calificar imágenes que tienen una escala BI-RADS 2 o 3. Debido a que no hay muchos modelos de clasificación de mamografías en escala BI-RADS disponibles públicamente, y que tareas relacionadas con el entrenamiento del modelo están fuera del alcance de este proyecto, se deberá asumir este defecto.

Seguridad

Se utilizó el programa Burp Suite para la realización de pruebas de penetración en la página desplegada, incluyendo aspectos tales como encriptado de contraseñas, autenticación con JWT, seguridad de headers (CORS) e inyecciones SQL entre otros, para un total de 10 pruebas. El sistema aprobó todas las pruebas de forma satisfactoria.

Carga

Las pruebas de carga se realizaron por medio de la herramienta JMeter, donde se simularon 10 usuarios concurrentes realizando el flujo de inicio de sesión, carga de 1 Figura y análisis de esta. Se determinó que en este escenario los tiempos de espera para realizar este flujo, ósea, el tiempo que un usuario espera la respuesta del sistema, asumiendo una conexión a internet estable, tiene una duración promedio de 24,83 segundos, con un tiempo máximo de 65,26 segundos. La mayoría de este tiempo es tomado por el análisis, con un tiempo promedio de 22,75 segundos y un tiempo máximo de 62,22 segundos.

Usabilidad

3 usuarios (radiólogos o profesionales en imágenes médicas) realizaron una prueba de usabilidad, desde crear una nueva cuenta hasta analizar imágenes y recibir los resultados, los aspectos que se evaluaron fueron diseño de la página, facilidad de navegación y funcionalidades. En general, los usuarios de prueba acordaron en que la página es visualmente atractiva, fácil de usar y ofrece funciones útiles para su trabajo. Adicionalmente, propusieron las siguientes mejoras:

- Incluir soporte para BI-RADS 0 y 6
- Incluir instrucciones en la sección de carga de imágenes para hacer más intuitivo el proceso.

VI- CONCLUSIONES

1. Análisis de impacto del proyecto

El sistema desarrollado en este proyecto tiene la capacidad de impactar positivamente el sector de salud, específicamente para el análisis de mamografías y prevención de cáncer de mama. Como se ha mencionado anteriormente, el objetivo de este sistema no es el de reemplazar al radiólogo, simplemente otorgarle una herramienta para apoyar su trabajo.

Impacto a corto y medio plazo

El proyecto posibilita el surgimiento de múltiples proyectos futuros orientados a expandir las funcionalidades existentes o expandir las capacidades de operabilidad del sistema por medio de mejoras a la máquina virtual de Google Cloud.

Impacto a largo plazo

A medida que se prueba la viabilidad del sistema, y se mejoran sus funciones y capacidades a lo largo de múltiples iteraciones, se espera que pueda ser implementado por múltiples hospitales y centros de salud en Colombia, ayudando a la detección temprana de cáncer de mama. También existe la posibilidad de que el sistema sea adaptado para poder ser adoptado por otros hospitales en diferentes países, por medio de la traducción de la plataforma y ajustes menores al modelo de clasificación.

Impacto en ingeniería de sistemas

Este proyecto tiene la capacidad de ser usado como base para la implementación de múltiples plataformas de análisis de imágenes médicas apoyadas por inteligencia artificial, como pueden ser rayos-X, resonancia magnética o tomografía. El mayor obstáculo para la creación de estos nuevos sistemas surge en la limitada disponibilidad de modelos de inteligencia artificial públicamente accesibles orientados hacia estos tipos de imágenes.

Impacto global

A nivel global, se espera facilitar el proceso de análisis de mamografías al darle a radiólogos acceso a una plataforma fácil de usar que les otorgue una segunda opinión o guía para realizar sus propios análisis.

2. Conclusiones y Trabajo Futuro

Los objetivos establecidos al inicio del desarrollo del proyecto fueron cumplidos satisfactoriamente, el prototipo diseñado cumple su objetivo de ser una herramienta que

apoye al radiólogo durante el proceso de análisis de mamografías, siendo al mismo tiempo una plataforma visualmente agradable e intuitiva, a la vez de adherirse a las estrictas leyes de protección de datos que vienen asociadas con sistemas médicos.

El reto principal para desarrollar un sistema como el presentado caen en la naturaleza de la información del paciente, no se puede almacenar nada que pueda usarse para identificarlo, por lo que hay que tener cuidado a la hora de diseñar el sistema y la base de datos.

Otro reto importante pero difícil de mediar es la naturaleza de los modelos de clasificación de imágenes médicas, pues en su mayoría son desarrollados de forma privada con fines investigativos, y los modelos que son públicamente accesibles no siempre son entrenados al punto de ser viables para sistemas de este tipo.

Aparte de obtener un dominio para la página para facilitar su acceso y poder implementar el protocolo HTTPS, el objetivo principal para trabajos futuros es el de mejorar el modelo de clasificación por medio de reentrenamiento o sustituirlo por uno nuevo, aunque debido a la ya mencionada limitada disponibilidad de modelos de clasificación de imágenes orientados a mamografías, se dificulta este proceso. Adicionalmente se pueden implementar otras funcionalidades que le otorguen más información al radiólogo, como mapas de calor en la pantalla de resultados que resalten áreas donde se encuentran las anomalías detectadas.

VII- REFERENCIAS

Organización Panamericana de la Salud. (2025, marzo 25). *Cáncer de mama*.

OPS/OMS. <https://www.paho.org/es/temas/cancer-mama>

American College of Radiology. (2013). *Breast Imaging Reporting and Data System (BI-RADS® Atlas)*. ACR.

LeCun, Y., Bengio, Y., & Hinton, G. (2015). *Deep learning*. *Nature*, 521(7553), 436–444. <https://www.nature.com/articles/nature14539>

Lee, R. S., Gimenez, F., Hoogi, A., Miyake, K. K., Gorovoy, M., & Rubin, D. L.

(2017). *A curated mammography data set for use in computer-aided detection and diagnosis research*. Scientific Data, 4, 170177. <https://www.nature.com/articles/sdata2017177>

McKinney, S. M., Sieniek, M., Godbole, V., Godwin, J., Antropova, N., Ashrafian, H., & Suleyman, M. (2020). *International evaluation of an AI system for breast cancer screening*. Nature, 577(7788), 89–94. <https://www.nature.com/articles/s41586-019-1799-6>

Kheiron Medical Technologies. (2023). *Mia: The AI breast screening solution*. <https://www.kheironmed.com/mia>

VIII- APENDICE

(1) *Reporte de Pruebas de Software*

Reporte de pruebas de software.pdf

(2) *Pruebas de software*

Pruebas de software.pdf

(3) *Documento de modelo*

Documento del modelo.pdf

(4) *Código fuente*

El código fuente completo perteneciente al proyecto se encuentra en el perfil de GitHub de Juan Esteban Villamil (*JuanesVillamil*), al cual se puede acceder a través del siguiente enlace: <https://github.com/Juanes-Villamil/Proyecto-de-Grado>

(5) *Software Requirements Specification*

SRS.pdf

(6) *Software Design Document*

SDD.pdf

(7) Manual de usuario

Manual de usuario.pdf

(8) Propuesta de proyecto

Propuesta para Proyecto de Grado - VF.pdf

(9) Plan de proyecto

Plan de proyecto (PMP).pdf